



T.C.

İSTANBUL MEDENİYET ÜNİVERSİTESİ

MÜHENDİSLİK VE DOĞA BİLİMLERİ FAKÜLTESİ

ENDÜSTRİ MÜHENDİSLİĞİ BÖLÜMÜ

MAKİNE ÖĞRENMESİ ALGORİTMALARINA DAYALI

HİSSE SENEDİ FİYAT TAHMİNİ

BİTİRME PROJESİ

Hazırlayan

TUNAHAN KAAAN KELEŞ

21120606312

İÇİNDEKİLER

ÖNSÖZ.....	3
1.GİRİŞ	4
2.LİTERATÜR TARAMASI.....	6
3.MATERYAL VE YÖNTEM.....	10
3.1. ZAMAN SERİLERİ ANALİZİ.....	10
3.1.1.Zaman Serilerinin Bileşenleri.....	11
3.2.MAKİNE ÖĞRENMESİ.....	13
3.2.1.Makine Öğrenmesi Algoritmaları.....	13
3.3.YAPAY SİNİR AĞLARI (NEURAL NETWORKS)	14
3.3.1. RNN(Recurrent Neural Network)	15
3.2.1.1.Gated Recurrent Unit (GRU).....	16
3.2.1.2.Long – Short Term Memory (LSTM).....	16
3.4. DERİN ÖĞRENME	17
3.4.1. Tensorflow ve Keras.....	18
3.5.SPK VE KAP	18
3.6. FİNANSAL RAPORLAR	19
3.6.1.Gelir Tablosu	19
3.6.2.Bilanço.....	20
3.6.3.Nakit Akış Tablosu	20
3.6.4. Özkaynak Değişim Tablosu.....	21
3.7.KORELASYON ANALİZİ	21
3.7.1.Korelasyon Katsayısı	21
3.7.2.Korelasyon Analizinin Adımları	22
4.BULGULAR	23
4.1.KORELASYON ANALİZİ	23
4.1.1.Toplam Varlıkların Korelasyonu.....	23
4.1.2.Hacim Değerlerinin Korelasyonu.....	27
4.1.3.Gelir Tablosunun Korelasyonu.....	29
4.3.EXTRATREES (EXTREMELY RANDOMIZED TREES).....	33
4.3.1.ExtraTrees Özellikleri.....	33
5.TARTIŞMA VE SONUÇ.....	35
6.KAYNAKÇA	36
7.EKLER	38

ÖNSÖZ

Günümüzde herhangi bir olayın, durumun veya gelişmenin sonucunu tahmin etmek çok önem kazanmıştır. Hızla gelişen teknolojiden Endüstri 4.0 ile başlayan müşterinin ihtiyacına göre üretim amaçlanmaktadır. Bunun için son yıllarda herkes tarafından konuşulan yapay zekanın her yerde yaygınlaşması çoğu bilim ve iş insanı tarafından ilke edinilmiştir. Özellikle son yıllarda akıllı cihazlar, kendi kendine hareket eden kobotlar, bir sürü insanın kas veya beyin gerektirerek yapması gereken işleri yapay zekâ yapabilmektedir.

Son zamanlarda finans alanında yapılan analizler ile şirketin fiyat durumu, azaldığı zamanlar ve arttığı zamanlar önceden tespit edilerek ona göre yatırım yapılabilir. Hisse senedi fiyat tahmini, yatırımcılar için büyük önem taşıyan bir konudur. Hisse senetleri, şirketlerin sermaye artırımını için çıkardığı, sahiplerine ortaklık hakkı ve temettü ödeme hakkı veren kıymetli evraklardır. Her şirketin hissesi yoktur. Yatırım şirketi olmak için devlet tarafından yönetilen SPK'nın (Sermaye Piyasa Kurulu) onaylaması gerekir. SPK hisselerin genel yönetim merkezidir ve şirketler SPK'dan onaylatarak verilerini KAP (Kamuoyu Aydınlatma Platformu) ile paylaşılır.

Bu çalışmamızda Vestel hisse senedi verilerinin on dört yıllık fiyat durumlarından yola çıkılarak belirli algoritmalar ile model kurma ve tahminleme çalışması yapılmıştır. Yapılan çalışmada algoritmanın genel yapısı anlatılmış, belirli hata oranı çerçevesinde model değerlendirilmiştir. Model kurulurken KAP'ta (Kamuoyu Aydınlatma Platformu) paylaşılan şirketin verileri kullanılarak korelasyon analizi ile model oluşturmada kararlılık amaçlanmıştır.

Ayrıca bu çalışma, hisse senedi piyasasında yatırım yapmak isteyenler için faydalı olabilecek bir kaynak niteliğindedir. Hisse senedi fiyat tahminleri, yatırımcıların karar verme süreçlerinde önemli bir rol oynar ve bu nedenle bu konunun doğru bir şekilde anlaşılması büyük önem taşır. Bu projede bizi destekleyen İstanbul Medeniyet Üniversitesi ve danışman hocamız Muhammet Raşit Cesur'a teşekkür ederiz.

1.GİRİŞ

Günümüzde herhangi bir olayın, durumun, tahmin edilmesi ve bu tahmine bağlı olarak iyileştirme çalışması yapılması çok önemlidir. Endüstri 4.0 ile başlayan müşterinin ihtiyacına göre üretim çoğu alanda yaygınlaşmıştır. Buna bağlı olarak üretilen ürünler analiz edilip artması veya azaltılması özellikle hangi zaman aralığında nasıl değişim gösterdiğini bilmek gerekir. Çünkü bu durumlara bağlı oluşan sonuçlar ile farklı alternatifler geliştirilebilir. Bu da herhangi bir kötü durum oluşmadan önce önlem almayı sağlar.

Finansal piyasalar alanında ise hangi hissenin hangi zaman aralıklarında nasıl fiyat değişikliği yaptığı; saatlik, günlük, haftalık, aylık ve yıllık analizler ile değişimin önceden öngörülmesi ve buna bağlı olarak inisiyatif alınması gerekir. Böylelikle finansal modelleme ortaya koyup zaman serilerine bağlı kalarak hisselerin değişimleri görülebilir. Bu değişimler ile şirkete yatırım yapacak olan kitle arasında doğrudan ilişki kurulur.

Şirketlerin kendileri ile ilgili her türlü bilgiyi KAP(Kamuoyu Aydınlatma Platformu) ile paylaşması gerekir. Kamuyu Aydınlatma Platformu, sermaye piyasası ile Borsa İstanbul mevzuatı gereğince kamuoyuna açıklanmasına gerek görülen işlem ve bildirimlerin e-imza olarak iletildiği elektronik sistemdir. Devlet tarafından yönetilen ve idari ve mali özerkliğe sahip düzenleyici ve denetleyici olan kamu kuruluşu ise SPK'dır. SPK şirketlerin piyasada adil ve etkin çalışmasını sağlar. Şirketler SPK'ya onaylatarak KAP(Kamuoyu Aydınlatma Platformu) ile genel yönetim kalemlerini, bilançolarını vs. açıklamak zorundadırlar. Bu veriler çerçevesinde hissenin genel durumu kontrol edilebilir. Bunlardan yola çıkarak hisse senedi fiyatlarının gelecekteki seyri hakkında tahmin yapmak, yatırımcılar için büyük bir değer taşır. Ancak, hisse senedi fiyatlarının tahmin edilmesi oldukça karmaşık bir konudur ve birçok farklı etkenin bir araya gelmesiyle şekillenir.

Son yıllarda, derin öğrenme tekniklerinin finansal piyasalarda başarıyla kullanıldığı birçok çalışma bulunmaktadır. Bu teknikler, büyük miktarda veriye dayalı olarak karmaşık ilişkileri tanımlama ve öğrenme yetenekleri sayesinde hisse senedi fiyat tahmini gibi finansal analiz problemlerinde etkili olabilmektedir.

Bu makalede, hisse senedi fiyat tahmini için derin öğrenme yaklaşımının kullanılması ve bu yaklaşımın başarısı üzerine bir analiz sunulacaktır. Çalışmada, öncelikle derin öğrenme modellerinin temel prensipleri ve kullanılan veri seti hakkında genel bir bilgi verilecektir. Kullanılan model LSTM (Long Short Term Memory) ve ExtrsTrees algoritmalarının nasıl çalıştığı ve hangi prensiplere dayandığı ayrıntılı bir şekilde açıklanacaktır.

Vestel şirketinin KAP'ta açıklanan 2014 yılından itibaren günümüze bilanço verileri başta olmak üzere iş anlaşmaları, temettüler, özel durum açıklamaları, yatırımları gibi veriler kullanılarak hisse fiyatına etkisi araştırılmış bu kapsamda korelasyon analizi kullanılarak hisse senedinin fiyatı arasındaki ilişkiye bakılmıştır. Korelasyon analizi; değişkenler arasındaki ilişki, bu ilişkinin yönü ve şiddeti ile ilgili bilgiler sağlayan istatistiksel bir yöntemdir. Bu bağlamda fiyata KAP verilerinin ilişkisi hakkında yorum yapmayı sağlar.

VESTEL şirketinin hisse fiyatı tahminleme modeli, modelin gerçeğe uygunluk fonksiyonu ile gerçek değerler ve kurulmuş model arasındaki ilişki gösterilecektir. Bu analiz sonucunda oluşturulan tahmin modelinin hata oranı RMSE ile bulunup onun üzerinden model doğruluk oranı hesaplanmıştır.

Bu makaledeki bir başka amaç, finansal piyasalarda derin öğrenme modellerinin kullanımının potansiyelini ve etkinliğini göstermek amacıyla yapılmıştır. Elde edilen sonuçlar, bu tür modellerin gelecekteki finansal analiz çalışmalarında daha fazla kullanılmasını teşvik etmek ve finansal piyasalardaki tahmin yeteneğini artırmak için bir temel oluşturabilir.

Çalışmanın giriş kısmında konu tanıtılıp amaç açıklanır. Literatür Taraması bölümünde ise hisse senedi fiyat tahmini ile ilgili bu zamana kadar yapılan makale, tez gibi çalışmalardan yirmi tanesi seçilerek hakkında bilgi verilmiştir. Materyal ve Yöntem kısmında bu çalışmada kullanılan makine öğrenmesi tekniği ile ilgili bilgi verilecek olup KAP platformundan alınan şirketlerin verileri incelenecek ve korelasyon analizi gösterilecektir. Bulgular kısmında ise LSTM modeli ile oluşturulan tahmin modeli, hesaplanan hata oranı açıklanacak olup algoritma kısmı anlatılacaktır. Sonuç kısmında ise yapılan çalışma değerlendirilecek ve önceden yapılan çalışmalarla yorumlanacaktır.

2.LİTERATÜR TARAMASI

Hisse senetlerinin fiyatını tahmin etmek bunlarla ilgili model kurmak veya belirli modeller oluşturmak yıllardır insanların merak ettiği durumlardan bir tanesidir. Bu konuda yapılan araştırmalar ve makaleler incelendiğinde özellikle performans analizi, trend analizi konuları herhangi bir konuda irdelenmiştir. Önceki veriler toplanarak bu verilere uygun makine öğrenmesi algoritmalarından uygun olan seçilmiş ve bununla ilgili model değeri hesaplanmıştır. Bu modelin uygunluk derecesi, doğruluğu ve hata oranı göz önünde olarak gelecek durumlar için tahminleme çalışmaları yapılmıştır.

Seher ARSLANKAYA, ŞEVVAL TOPRAK(2021) yılındaki çalışmalarında Makine Öğrenmesi ve Derin Öğrenme Algoritmalarını Kullanarak Hisse Senedi Fiyat Tahmini yapmışlardır. Arslankaya ve Toprak (2021) yılındaki bu çalışmalarında belirli algoritmalar ile Ereğli hisse senedi fiyat tahmini yaparak hangisinin en iyi performans verdiği hesaplanmaya çalışılmıştır. Yöntem olarak polinomal regresyon, Random Forest, RNN, LSTM kullanmışlardır. Araştırmanın sonucunda ise MAE, MSE, RMSE sonuçları ile tahmin oranı en yüksek olan Random Forest ve LSTM algoritmaları olmuştur.

(KOÇ USTALI et al., 2021) yılındaki araştırmalarında Makine Öğrenmesi Teknikleri ile Hisse Senedi Fiyat Tahmini yapmışlardır. BİST 30 Endeksi firmalarının 2010-2019 yılları arasındaki üçer aylık finansal tablolarına bakılmış ve kapanış fiyatları ile ortalamalar alınmıştır. Bu şekilde veriler temin edildikten sonra belirli algoritmalar kullanılarak her bir firmaya ait hisse senedinin gelecek fiyatı tahmin edilmiştir. Çalışmada YSA, XGBoost, Rastgele Orman(RO) kullanılırken sonuç olarak 3 farklı model R^2 ile analiz edilmiştir. En iyi performansı veren XGBoost algoritması olmuştur.

Eda Çınaroğlu, Tunahan Avcı (2020) yılında THY Hisse Senedi Değerinin Yapay Sinir Ağları İle Kestirimini yapmışlardır. (ÇINAROĞLU & AVCI, 2020) çalışmalarında THY kapanış değerlerinin YSA modeli ile BIST Ulaştırma Endeksleri, petrol ve dolar fiyatlarına bağlı olarak değişimi incelenmiştir. Bu çalışma için YSA ve Korelasyon analizi kullanılırken sonuç olarak en iyi MSE değerleri eğitim kümesi için 0.0031 test kümesi için 0.0030 olarak hesaplanmıştır.

Mustafa Tuncer Çalışkan, Devran Deniz (2021) yılındaki çalışmalarında Yapay Sinir Ağlarıyla Hisse Senedi Fiyatları ve Yönlerinin tahmin etmişlerdir. BİST30 endeksine ait 30 hisse senedinin günlük bazda fiyatları ve fiyat yönleri bazı algoritmalar ile tahmin edilmeye çalışılmıştır. Çalışma için yöntem olarak YSA, doğrusal ve doğrusal olmayan regresyon analizi, Random Walk, GARCH, ARIMA, Doğrusal olmayan regresyon kullanılmıştır. Sonuç olarak BİST 30'dak i hisse senetleri için günlük bazda fiyat yönü ortalama % 58 oranında doğru tahmin edilmiştir. Yapılan tahminlerin ortalama mutlak yüzde hatası %1,80, ortalama mutlak hatası ise 21 Kuruş olmuştur.

Anita Rácz, Dávid Bajusz, Károly Héberger (Rácz et al., 2021) yılındaki çalışmalarında ilaç güvenliği ile ilgili sınıflandırma görevleri için makine öğrenimi modellerini incelemişlerdir. Rácz ve diğ. (2021) yılındaki bu çalışmalarındaki amacı ADME(emilim, dağılım, metabolizma ve atılım) ile ilgili makine öğrenimi odaklı sınıflandırma çalışmalarının feld'sindeki mevcut eğilimleri özetlenir.Makine öğrenmesi algoritmalarından Tree-based algorithms, Neural networks, Support vector machine, Naïve Bayes algorithms, Nearest neighbor-based algorithms kullanılmıştır. Araştırmanın sonucunda ise hesaplamalı ilaç keşfinin merkezi sorusu ve artan veritabanları, hızlı ve verimli açık kaynak yeni algo'nun modellenmesi ve geliştirilmesi için platformlar ritimler, özel makine öğrenimi modellerinin olduğu kanıtlanmıştır.

Dimple Tiwari, Bhoopesh Singh Bhati (Tiwari et al., 2022) çalışmalarında Covid-19'un Dünya etkilerini makine öğrenimi tekniklerini kullanarak analiz ve tahmin etmeye çalışmışlardır.

Tiwari ve Bhati(2022) Covid-19 gözlenen semptomlarla ilgili çeşitli gerçekleri sunmayı amaçlamışlardır. Yöntem olarak Naive Bayes, SVM, Doğrusal Regresyon kullanılırken sonuç olarak makine öğrenimi ve yapay zekanın tahmin, tarama ve ilaç geliştirmede büyük ölçüde daha fazla popülerlik kazandığına ulaşmışlardır.

Özlem Alpay (ALPAY, 2020) çalışmalarında LSTM Mimarisi Kullanarak USD/TRY Fiyat Tahmini yapmıştır. LSTM ile 2000 ile 2017 yılları arasında USD/TRY paritesi veriseti kullanılarak stok verileri ve finansal verilerin tahminini gerçekleştirmiştir. Sonuç olarak epoch değerinin artması ile modelin başarısı da artmaktadır. Modelin başarı oranı belli bir epoch değerinden sonra çok küçük birimlerde artacağı için bu noktalarda eğitim sonlandırılabilir. Batch değeri küçük seçildiği zaman model kendini ezberleyebilmektedir. 2000’li yıllarda USD/TRY paritesi ortalama 0,6 oranından 2016 yılında ise ortalama 3,5 oranına yükselmiştir.

Cem Şener, Uğur Şener (Şener & Şener, 2019) çalışmalarında Monte Carlo Simülasyonu ile Hisse Senedi Fiyat Tahminleri yapmışlardır. Bu çalışmalarında Havayolu hisseleri referans alınarak Monte Carlo Simülasyonu yöntemi ile Türk ve Amerikan hisse senedi piyasaları arasında TL ve USD bazında bir karşılaştırma yapılmıştır. Yöntem olarak Varyans-Kovaryans Yöntemi, Tarihi Simülasyon Yöntemi ve Monte Carlo Simülasyonu Yöntemi kullanılmıştır. Bundan hareketle Türk Hava Yollarının ve American Airlines’ın dolar kuru üzerinden yıllık volatilitelerine bakıldığında iki şirket arasında çok ciddi farkların olduğu gözlemlenmiştir. Türk Hava Yollarının dolar kurundan yıllık volatiliteler değeri 12,03305213 olduğu gözlemlenmiş, American Airlines’ın ise yıllık volatiliteler değerinin 0,400099 olduğu belirlenmiştir. Bu sonuçla THY’nin fiyat dalgalanması daha çok sonucuna varmışlardır.

(Song et al., 2022) çalışmalarında Bariatrik metabolik üzerine yayınların manzarasını analiz etmeyi amaçlamışlardır. Yöntem olarak makine öğrenmesi algoritmalarından Neural Networks, Clustering kullanılmıştır. Sonuç olarak araştırma konuları bms'nin esas olarak beş kümeye odaklanıldı: bariatrik cerrahi müdahale, klinik vaka yönetimi, temel araştırma, vücut yapısı ve cerrahi risk durumu. Bu durumlar üzerine seviye tespitleme yapılmıştır.

Gökhan Alagöz (CREDIT RISK ANALYSIS USING MACHINE-LEARNING ALGORITHMS, n.d. 2021) yılındaki çalışmasında kredi risk analizi üstüne çalışmıştır. gerçekte başarılı (0) veya başarısız (1) olan kredilerin makine öğrenmesi algoritmaları kullanılarak bu değişkenlerin etkisine göre sonucunun tahmin edilmesi üzerine araştırmayı amaçlamıştır. Yöntem olarak Lojistik regresyon, Rastgele Orman, Yapay Sinir Ağları kullanılırken gereksiz verilerin düşük anlamla kullanılması ve bilgi değeri engellendi. Performans değerlendirme kriterleri de test edildi modelin performansını ölçülmüştür.

(KUZU et al., 2021) çalışmasında Güneydoğu Anadolu Bölgesinin tarımsal durumunu incelemişlerdir. Kuzu ve diğ. (2021) Güneydoğu Anadolu Bölgesinde tarımsal mekanizasyon düzeyinin 2010-2019 yıllarındaki değişimi ve gelecek yıllar için trend analizi ile belirlenmesini amaçlamışlardır. Yöntem olarak Trend analizi, en küçük kareler yöntemi, eğri uydurma, hareketli ortalama, yarıyıl ortalamalar yöntemi kullanılmıştır. Çalışmanın sonucunda ise Güneydoğu Anadolu Bölgesinde yıllara göre işlenen alana düşen traktör gücü ve 1000 ha alana düşen traktör sayısı verilerinde artış saptanmıştır.

Özlem Akekmekçi (Bo, 2022) araştırmasında Makine Öğrenmesi Algoritmaları Kullanılarak Döviz Kuru Tahmini yapmıştır. Farklı kur pariteleri için döviz kuru tahminleri gerçekleştirmiştir. Machine learning algoritmalarından En küçük kareler, lasso lojistik, karar ağaçları, rastgele ormanlar, destek vektör makineleri, XGBoost kullanılmıştır. Araştırmanın sonucunda Döviz kuru hareketlerinin metotta belirtilen ML algoritmaları ile performansı tespit edilip en iyi sonuç veren bulunmaya çalışılmıştır.

Dilşad Tülgen Çetin (ÇETİN, 2022) Antalya-Isparta-Burdur Bölgesi Konut Fiyat Endeksinin Makroekonomik Göstergeler ve Hisse Senedi Endeksi Kullanılarak Yapay Zekâ ile Tahminini araştırmıştır. Çalışmada son yıllarda konut fiyatlarının en çok artan ülke Türkiye olması ve Türkiye'de en çok artan bölgenin Antalya-Isparta olmasından dolayı konut fiyatları analizi tahmin edilmiştir. Yöntem olarak YSA, regresyon, Çok Katmanlı Geri Beslemeli Yapay Sinir Ağı Modeli kullanılmıştır. Sonuç olarak bölgenin konut fiyatları, %5,6 Ortalama Mutlak Yüzde Hata (MAPE) ve %99,97 R2 oranında yüksek doğrulukta tahmin edilmiştir.

Zühal Yurtsızozğlu (YURTSIZOĞLU, 2021) çalışmasında Salgın Dönemi Kulüp Hisse Değerlerinde Ekonomik Kayıplarını incelemiştir. Yurtsızozğlu(2021) Covid 19'dan dolayı ekonomik kayıp yaşayan 4 Türk futbol kulübünün hisselerinin ve ekonomilerinin analizi baz alınarak araştırma yapmıştır. Yöntem olarak Trend analizi kullanılırken araştırmada baz yıla göre %50'lere varan değer kayıpları yaşanırken (Fenerbahçe ve Beşiktaş gibi), Galatasaray'da baz yıla göre en düşük değer kaybı yaklaşık %6'lar civarındadır. Trabzonspor hisse senetleri baz yıla göre negatif değerler almamıştır.

İbrahim TAMAM, Mukadder İnci BAŞER (Tamam & Başer Kolcu, 2017) çalışmalarında Türkiye'deki Tıp Fakülteleri ile Süleyman Demirel Üniversitesi Tıp Fakültesi Öğrenci Trendinin Değerlendirmişlerdir. Tamam ve Başer (2017) çalışmalarında Türkiye'deki tıp fakülteleri sayısındaki ve bu fakülteler ile Süleyman Demirel Üniversitesi Tıp Fakültesi'ndeki (SDÜTF) öğrenci sayılarındaki değişimin değerlendirilmesi amaçlamışlardır. Bu çalışmada Korelasyon Analizi ve Regresyon Analizini kullanılırken araştırmanın sonucunda tıp fakültelerinin sayısı ile tıp fakültelerine alınan öğrenci sayıları arasındaki korelasyondan yola çıkılarak, son 10 yılda Türkiye'deki hekim sayısında hızlı bir artışın hedeflendiği söylenebilir.

Pier Francesco Orrù, Andrea Zoccheddu, Lorenzo Sassu (Orrù et al., 2020) çalışmalarında bir santrifüjün arıza tahmini ve arıza tahmini için belirli ML algoritmaları inceleme yapmışlardır. Orrù ve diğ.(2020) çalışmalarında hierarchical symbolic analysis (HSA), convolutional neural network (CNN) SVM, ANN yöntemlerini kullanmışlardır. Sonuç olarak petrol ve gaz endüstrisinde dönen makinelerin arıza teşhisi için bilinçli karar vermeyi amaçlayan; akış hızı, iki yatak titreşimi, iki eksenel yer değiştirme ve üç motor bobini sıcaklığı verilerini kullanıp ML algoritmaları ile yüksek ve son derece doğruya yaklaşan optimum ML algoritmasını bulmuşlardır.

Evren Özgür (2013, n.d.) yılındaki çalışmasında 1971-2011 yılları arasını kapsayan günlük yağış verilerinin bileşenlerine yıllık ve bölgesel Mann-Kendall trend testi uygulanmıştır. Yağış verileri kar ve yağmur olarak ayrı ayrı ele almıştır. Özgür (2013) çalışmasında Trend analizi, Mann-Kendall Testi kullanırken araştırmanın sonucunda bölgesel olarak trend incelendiğinde, kullanılan dört bölgede de azalan yönde trend olduğu ortaya çıkmıştır. Kar ile toplam yağış oranındaki azalmanın genel olarak yükseklikle artış gösterdiği sonucuna varılmıştır.

Ali ÖZER, Abdulkadir KAYA, Nevin ÖZER (2011 et al., n.d.) çalışmasında Hisse Senedi Fiyatları ile Makroekonomik Değişkenlerin Etkileşimini ele almıştır. Özer ve diğ.(2011) amaçları Ocak 1996- Aralık 2009 dönemi aylık verileri kullanılarak, İMKB 100 Endeksi ile bazı makroekonomik değişkenler arasında bir ilişki olup olmadığını tespit etmektir. Çalışmada En Küçük Kareler Tahmin Yöntemi, Johansen-Juselius Eşbütünleşme Testi, Granger Nedensellik Testi, VEC modellerini kullanmışlardır. Araştırma sonuçlarında ise hisse senedi fiyatı ile bazı makro ekonomik değişkenler arasında uzun dönemli anlamlı bir ilişki bulunmaktadır. EKK tahmin sonuçlarına göre İMKBDE değişkeni ile tüm değişkenler (SÜE, KUR, TÜFE, M1, ALTIN, FAİZ ve DTD) arasında anlamlı ilişkiler bulunduğu saptanmıştır.

Daihong Li, Zhili Tang, Qian Kang, Xiaoyu Zhang (Li et al., 2023) çalışmalarında Sıkıştırılmayı Tahmin Etmek için Makine Öğrenimine Dayalı Yöntem Betonun Mukavemetini hesaplamaya

alıřmıřlardır. Asıl amaları betonun basın dayanımının tahminidir. Yöntem olarak ANN,SVM, Decision Trees, Classification and Regression Tree kullanılmıřtır. Sonu olarak gelecekteki arařtırmalar iin veri kümesini daha da zenginleřtirmeye ihtiya vardır ve sıkıřtırma ile ilgili daha fazla faktörü göz önünde bulundurmanın yanı sıra veri miktarının artırılması gerekmektedir.

Fatih ERİK (2021 n.d.) alıřmalarında BIST 30'UN PERFORMANSLARININ Karřılařtırılması MAKİNE ÖĞRENİMİ ALGORİTMALARINI KULLANARAK PORTFÖYLER üzerinedir. ERİK (2021) BIST 30 hisselerinin 1 ay, 2, ay, 3 ay, 4 ay, 6 ay ve 12 aylık fiyatları tahmin edilmiş ve bu aylara göre portfoy revizyonunun yapıldığı 6 strateji oluşturulmuştur. kullanılmıřtır. Arařtırmanın sonucunda ise BIST 30 endeksinin fiyatları kullanılarak belirli ML algoritmaları ile eřitli portföyler oluşturulmuş ve fiyat tahminlemesi yapılmıřtır.

3.MATERYAL VE YÖNTEM

Geçtiğimiz yıllara yapay zekâ damga vurmuştur. Makine öğrenmesi, derin öğrenme ve yapay sinir ağları hakkında sayısız makale yayınlanmıştır. Sürücüsüz arabalar, sanal asistanlar ortaya çıktı. İnsanların yapabildiği işi robotlar da yapmaya başladı. Önceden sadece insanların yapabildiği nitelikli işleri şimdi yapay zekâ da yapabiliyor. Bunun için yapay sinir ağları, derin öğrenme ve makine öğrenmesi çok önemli rol oynamaktadır. Belirli zamana bağlı olarak değişen veriler alınarak yorumlanmaya ve sonuç üretilmeye çalışılıyor.

Hisse senedi fiyat tahmini yapmak için ise birçok farklı yöntem kullanılmaktadır. Bu yöntemlerin bazıları temel analize dayanırken, bazıları ise teknik analize odaklanmaktadır. Ayrıca, makine öğrenimi gibi daha gelişmiş teknikler de hisse senedi fiyat tahmini için kullanılmaktadır. Hisse senedi fiyat tahmininde kullanılan bazı temel yöntemler:

Temel Analiz: Temel analiz, bir şirketin mali durumunu, endüstri trendlerini ve ekonomik faktörleri analiz ederek hisse senedi fiyatlarını tahmin etmeye odaklanır. Bu yöntemde şirketin gelir tablosu, bilançosu, nakit akışı tablosu gibi finansal veriler incelenir ve şirketin değeri ile hisse senedi fiyatları arasındaki ilişki incelenir.

Teknik Analiz: Teknik analiz, hisse senedi fiyatlarının geçmiş performansını ve piyasa verilerini inceleyerek gelecekteki fiyat hareketlerini tahmin etmeye çalışır. Bu yöntemde grafikler, göstergeler ve matematiksel modeller kullanılarak fiyat hareketlerinin analizi yapılır.

Hisse senedi fiyat tahmini yaparken hissenin fiyat değişikliğine en çok etki edenler şirketin geliri, gideri dönen varlıkları, duran varlıkları, borçları vs. ile ilişkilidir. Bir şirket bu verilerinin

3.1. ZAMAN SERİLERİ ANALİZİ


Bir zaman serisi, belirli bir kronolojik zaman sırasına göre bir dizi veya sayısal veri noktasıdır. Çoğu durumda, bir zaman serisi, zaman içinde sabit aralık noktalarında alınan bir dizidir. Zaman serileri bize mevsimsel kalıpları, eğilimleri ve dış etkenlerle olan ilişkileri gösterir. Özellikle hava durumu raporları, deprem tahmini, astronomi, matematiksel finans gibi gerçek hayat problemlerinde kullanılır.

Analizlerde zaman serileri üzerinde çeşitli istatistiksel teknikler ve modeller kullanılarak verilerin özellikleri ortaya çıkarılır. Tahmin yapılacak grafiğin sayısal verileri bir grafiğe işlenir. Burada daha çok çizgi grafik kullanılır. Çizgi grafiklerinin davranışına göre zaman serileri sınıflandırılır. Bu sınıflandırma sayesinde tahmin yapmak daha kolay hale gelmektedir. Zaman serilerinin sektör olarak kullanım alanları:

- Ekonomik göstergelerin tahmini
- Finansal piyasa analizleri
- Üretim ve stok yönetimi
- Hava durumu tahmini
- Enerji tüketimi tahmini

Özellikle finans ve ekonomi alanında zaman serileri tahmini kritik bir öneme sahiptir. Hisse senedi fiyatlarının gelecekteki seyrini tahmin etmek için bu yöntemler sıklıkla kullanılır. Zaman serisi ile ilgili grafikler verinin gidişatına göre farklı isimlendirilir.

Tablo 3.1.Zaman Serisi Grafikleri [1]




Zaman serisi tahmini, önceden gözlemlenen zaman serisi değerlerine dayalı olarak gelecekteki değerleri tahmin etmek için bir model oluşturma yöntemidir. Zaman serileri makine öğreniminin önemli bir parçası olup gözlemlenen zaman serisi verilerinde mevsimsel bir model veya eğilim belirler. Buradaki amaç bu oluşturulan modeli kullanarak gelecekteki tahminleri yapmaktır.

3.1.1.Zaman Serilerinin Bileşenleri

Bir veri kümesini anlamak için zaman serisi analizi teknikler sağlar. Bunlardan en faydalısı veri setinin dört parçaya ayrılmasıdır:

- ❖ Level(Düzye) : Serinin düz bir çizgi veya durağan olması durumudur.

Tablo 3.2.Durağan Veri Seti [1]




- ❖ Trend: Serinin zaman içindeki doğrusal artan veya azalan davranışı görülür.

Tablo 3.3.Trendli Veri [1]




- ❖ Seasonality (Mevsimsellik): Zaman içinde yinelenen davranış kalıpları veya döngüleri vardır.

Tablo 3.4.Mevsimsellik Grafiği [1]



- ❖ Cycle (Döngüsellik): Düzenli aralıklarla mevsimsellik vardır.

Tablo 3.5.Döngüsel Veri [1]



3.2.MAKİNE ÖĞRENMESİ

Makine öğrenmesi (ML), bilgisayarların, verilerden öğrenerek ve belirli görevleri insan müdahalesi olmadan yerine getirebilmesi için algoritmalar geliştiren bir yapay zeka dalıdır. ML, istatistiksel yöntemler kullanarak büyük miktarda veriyi analiz eder ve bu verilerden anlamlı kalıplar çıkarır. Bu kalıplar, gelecekteki veri noktaları hakkında tahminler yapmak veya kararlar almak için kullanılır. Temel amaç; verilere dayanarak modeli en optimum hale getirmektir.

3.2.1.Makine Öğrenmesi Algoritmaları

Makine Öğrenmesi algoritmaları; büyük veri kümelerinde desenleri ve korelasyonları bulmak ve bu analize dayalı en iyi kararları ve tahminleri yapmak için eğitilir. Bu eğitilmenin sonucu genel olarak: Denetimli öğrenme (supervised learning), Denetimsiz öğrenme (unsupervised learning), ve Pekiştirmeli öğrenme (reinforcement learning) olarak üç kategoriye ayrıştırılır.

3.2.1.1. Denetimli Öğrenme (Supervised Learning)

Bu tür algoritmalar, her veri noktasının hem giriş hem de çıkış değerleri bilinir. Amaç, giriş değerlerine dayalı olarak doğru çıkışları tahmin etmektir. Bu tür algoritmalara örnek olarak aşağıdakiler verilebilir:

1. Doğrusal Regresyon (Linear Regression): Sürekli sonuçları tahmin etmek için kullanılır.
2. Lojistik Regresyon (Logistic Regression): İkili sınıflandırma problemleri için kullanılır.
3. Destek Vektör Makineleri (SVM): Bir marjin aralığına maksimum noktayı en küçük hata ile alabilecek şekilde doğru ya da eğriyi belirlemektir.
4. Karar Ağaçları (Decision Trees): Veri seti içindeki karmaşık yapıları basit karar yapılarına dönüştürmek
5. Rassal Ormanlar (Random Forests): Birden fazla karar ağacının ürettiği tahminlerin bir araya getirilerek değerlendirilmesi
6. K-En Yakın Komşu (K-Nearest Neighbors, KNN): Veri noktalarını, en yakın komşularına dayanarak sınıflandırır.
7. Yapay Sinir Ağları (Artificial Neural Networks): Karmaşık ve büyük veri setlerinde hataları minimum yapacak şekilde matematiksel form veya kural seti çıkarmak

3.2.1.2. Denetimsiz Öğrenme (Unsupervised Learning)

Bu algoritmalar, etiketsiz verilerle çalışır ve verideki gizli yapıları ortaya çıkarmaya çalışır. Bu tür algoritmalara örnek olarak aşağıdakiler verilebilir:

1. Kümelenme Algoritmaları (Clustering Algorithms): Birbirine benzeyen veri parçalarını ayırma işlemidir ve kümelem yöntemlerinin çoğu veri arasındaki uzaklıkları kullanır. K-Means, Hierarchical Clustering örnek olarak verilebilir.
2. Boyut İndirgeme Algoritmaları (Dimensionality Reduction Algorithms): Yüksek boyutlu veri setlerinin boyutunu azaltarak, veriyi daha az sayıda özelliğe (değişkene) indirgemeyi amaçlar. Principal Component Analysis (PCA), t-Distributed Stochastic Neighbor Embedding (t-SNE) örnektir.
3. Bağlantısızlık Analizi (Association Rule Learning): Veri kümesi içindeki yaygın örüntülerin, nesneleri oluşturan nitelikler arasındaki ilişkilerin bulunmasıdır. Apriori, Eclat örnek olarak verilebilir.

3.2.1.3. Pekiştirmeli Öğrenme (Reinforcement Learning)


Bu tür algoritmalar, bir ajan (agent) ve bir ortam (environment) arasındaki etkileşimlere dayanır. Ajan, belirli bir ödül (reward) almak için eylemler (actions) gerçekleştirir ve bu süreçte en iyi stratejiyi öğrenir.

1. Q-Learning
2. Deep Q-Networks (DQN)
3. Policy Gradient Methods

Makine öğrenmesi algoritmalarının seçimi, problem türüne, veri yapısına ve eldeki hedefe göre değişir. Her algoritmanın güçlü ve zayıf yönleri vardır, bu yüzden uygun algoritmanın seçimi dikkatli bir analiz ve test süreci gerektirir.

3.3.YAPAY SİNİR AĞLARI (NEURAL NETWORKS)

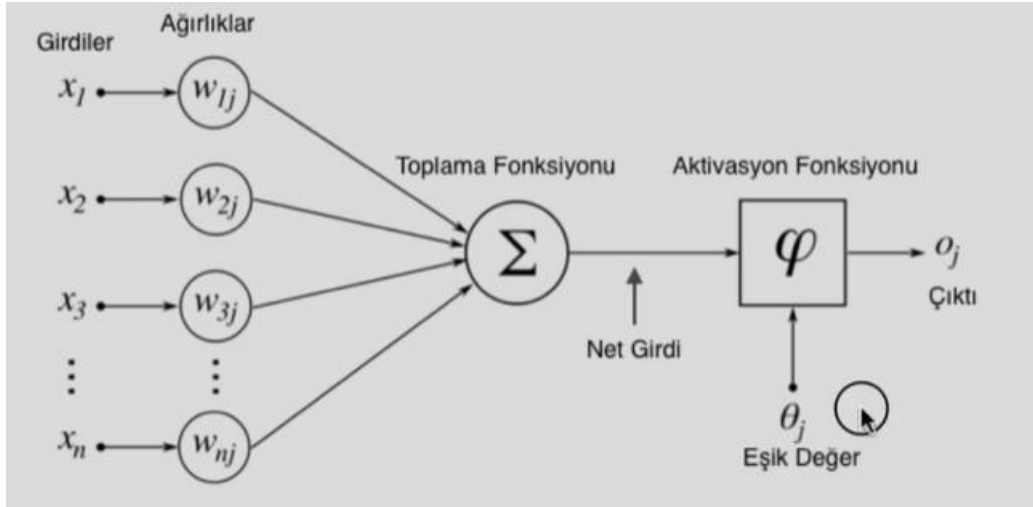
İnsan beyninin çalışma şeklini taklit etmeye çalışan ve genellikle derin öğrenme gibi alanlarda kullanılan bir yapay zekâ modelidir. Bu ağlar, insan beynindeki sinir hücrelerinin (nöronların) çalışma şeklini temel alır. İnsan beynindeki normal bir sinir hücresi aşağıda gösterilmiştir:



Şekil 3.1.Normal Sinir Hücresi [1]

- Dendritler: Sinir hücresinin (nöronun) gövdesinden çıkan, genellikle kısa ve dallı uzantılardır. Dendritler, diğer sinir hücrelerinden gelen uyarıları alarak sinir hücresine iletilmesini sağlar.
- Akson: Sinir hücresinin (nöronun) gövdesinden uzanan uzun, tek bir uzantıdır. Akson, hücre gövdesinden alınan uyarıları diğer sinir hücrelerine veya hedef dokulara iletmek için kullanılır.
- Sinapsis: Sinir hücreleri arasındaki iletişimi sağlayan bağlantı noktalarıdır. Bir sinapsis, bir sinir hücresinin dendritleri veya hücre gövdesi ile diğer bir sinir hücresinin akson ucu arasındaki bağlantıyı ifade eder.
- Soma (Hücre Gövdesi): Sinir hücresinin (nöronun) ana gövdesidir. Yapay sinir ağları, birçok nöron adı verilen birimlerden oluşur. Her bir nöron, girdi verilerini alır, bu verileri işler ve bir çıkış üretir. Bu yapay nöronlar, genellikle katmanlar halinde düzenlenir. Bir girdi katmanı, bir veya daha fazla gizli katman (hidden layer) ve bir çıkış katmanı bulunabilir.

Yapay sinir ağı, öğrenme süreci boyunca ağırlıkları ve eğimleri ayarlayarak veriler arasındaki ilişkileri öğrenir. Bu süreçte, ağıın çıkışı gerçek sonuçlarla karşılaştırılır ve ağırlıkların ve eğimlerin güncellenmesiyle ağıın performansı iyileştirilir.




Şekil 3.2.Yapay Sinir Ağı [1]

Yapay sinir ağıları, görüntü tanıma, doğal dil işleme, ses tanıma gibi birçok alanda kullanılır. Derin öğrenme gibi tekniklerle birleştirildiğinde, yapay sinir ağıları karmaşık veri yapılarından anlamlı özellikler çıkarmak ve bu özellikleri kullanarak karmaşık görevleri gerçekleştirmek için kullanılır.

3.3.1. RNN(Recurrent Neural Network)

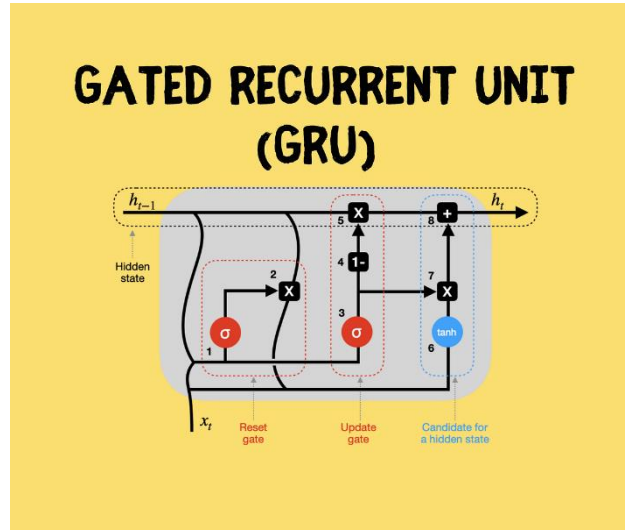
Recurrent Neural Network (RNN), sıralı veri üzerinde işlem yapabilen bir yapay sinir ağı türüdür. Sıralı bir veri girişini işler ve belirlenen modeldeki şekilde verileri dönüştürerek bir tahmin ortaya oyar. Bir derin öğrenme modelidir. RNN'lerin dil modeli, zaman serisi tahmini, konuşma tanıma ve diğer sıralı veri problemleri gibi uygulamalarda etkili olmasını sağlar.



Şekil 3.3.RNN Yapısı [2]

RNN'ler içinde sıklıkla kullanılan iki yapı vardır:

3.2.1.1.Gated Recurrent Unit (GRU): Tekrarlayan sinir ağlarının (Recurrent Neural Networks, RNN) bir türüdür ve özellikle sıralı veriyle çalışırken uzun süreli bağımlılıkları modellemek için kullanılır.



Şekil 3.4.GRU Yapısı [2]

3.2.1.2.Long – Short Term Memory (LSTM): Derin öğrenme alanında özellikle zaman serileri ve doğal dil işleme gibi sekans verileri üzerinde etkili bir şekilde çalışabilen bir tür rekürrent sinir ağı (RNN) modelidir. LSTM, özellikle uzun vadeli bağımlılıkları ele alabilen ve aynı zamanda kısa vadeli dalgalanmalara da duyarlı olan bir yapıya sahiptir. LSTM, tipik RNN modellerinin karşılaştığı sorunları çözmek amacıyla geliştirilmiştir.

LSTM'nin temel özellikleri şunlardır:

1.Hücre Durumu (Cell State): LSTM, bilgi depolamak için özel bir bileşene sahiptir. Bu bileşen hücre durumu olarak adlandırılır ve bilgiyi taşır. Hücre durumu, ağıın farklı bölümlerinden bilgi eklemek ve çıkarmak için tasarlanmıştır.

2.Gates (Giriş Kapıları): LSTM'nin ana yapı taşları, giriş, çıkış ve unutma kapılarıdır. Bu kapılar, hücre durumu üzerinde hangi bilgilerin geçmesine izin verileceğini kontrol eder. Her bir kapı, sigmoid aktivasyon fonksiyonu tarafından kontrol edilen ağırlıklı bir girişle çalışır.

- Unutma Kapısı (Forget Gate): Hangi bilgilerin unutulacağını belirler.
- Giriş Kapısı (Input Gate): Hücre durumuna hangi yeni bilgilerin eklenmesine izin verileceğini belirler.
- Çıkış Kapısı (Output Gate): Hangi hücre durumunun çıkış olarak kullanılacağını belirler.

3.Aktivasyon Fonksiyonları: LSTM'de genellikle sigmoid (σ) ve tanh (tanjant hiperbolik) aktivasyon fonksiyonları kullanılır. Sigmoid, 0 ile 1 arasındaki değerleri üretirken, tanh -1 ile 1 arasındaki değerleri üretir. Bu özellikler, kapıların (gates) ve hücre durumunun düzenlenmesinde önemlidir.

Bir örnek üzerinden açıklamak gerekirse, diyelim ki bir dil modeli LSTM kullanıyor. LSTM, cümle içindeki kelime sıralarını ve anlam ilişkilerini öğrenir. Eğer bir kelimenin anlamı cümle

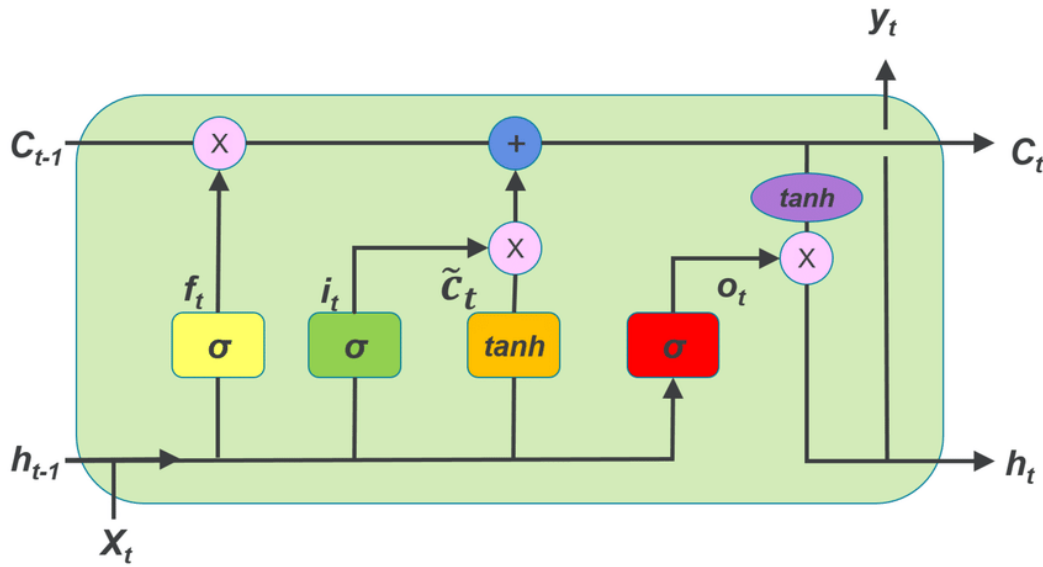
içindeki başka bir kelimenin anlamına bağlıysa, LSTM bu uzun vadeli bağımlılığı öğrenip kullanabilir.

Örneğin:

“My name i...” cümlesinde kelime sıralarını ve anlam ilişkilerini öğrenmeye çalışır. Bu cümlede bağlamdan yola çıkarak sondaki kelimenin ‘is’ olduğunu bulur.

Başka bir örnek;

“Bu film çok heyecan vericiydi, finali beklenmedik bir sürprizle sona erdi.” cümlesi ele alınacak olursa LSTM, "finali" kelimesini görünce, bu kelimenin önemli bir nokta olduğunu anlayabilir ve bu bilgiyi hücre durumunda saklayabilir. Sonraki bir kelime olan "beklenmedik" kelimesini gördüğünde, bu bilgiyi kullanarak bağlamı daha iyi anlayabilir ve daha doğru bir tahmin yapabilir.



Şekil 3.5. LSTM Yapısı [2]

Sonuç olarak LSTM, özellikle uzun vadeli bağımlılıkları ele alabilme yeteneği sayesinde birçok zaman serisi analizi, doğal dil işleme ve benzeri uygulamalarda başarıyla uygulanmaktadır.

3.4. DERİN ÖĞRENME

Derin öğrenme (deep learning), 2000 yıllarının başında konuşulmaya başlayan makine öğrenmesinin çok popüler alt disiplinlerinden biridir. Yapay sinir ağları gibi algoritmaların kullanılarak karmaşık veri yapılarından öğrenme yeteneğine sahip bir yapay zeka alt dalıdır. Bu algoritma türü, birçok katmandan oluşan yapay sinir ağlarını kullanarak karmaşık görevleri öğrenebilir ve genellikle büyük miktarda veriyle beslenerek bu görevleri gerçekleştirebilir.

Bu teknik, karmaşık veri yapılarından anlamlı özellikler çıkarmak ve bu özellikleri kullanarak karmaşık görevleri gerçekleştirmek için oldukça etkili bir yöntemdir. Bu nedenle, derin öğrenme günümüzde yapay zekâ alanında önemli bir yer tutmaktadır.

Bir model ne kadar fazla veri üretirse uygulama alanındaki başarısızlıkları o kadar azalacaktır. Derin öğrenme için veri, bundan dolayı çok önemlidir. Dünyada yaklaşık olarak yılda 41 zettabyte veri üretilmesi ve teknolojinin her geçen gün daha da ilerlemesi göz önünde bulunursa derin öğrenme daha da çok etkisini hissettirmektedir.

Derin öğrenmenin kullanıldığı başlıca sektörler:

- ❖ Doğal Dil İşleme (NLP): Metin çevirisi, metin oluşturma, duygu analizi.
- ❖ Ses Tanıma: Konuşma tanıma, sesli komutlar.
- ❖ Otonom Araçlar: Nesne tanıma, yol işaretleri tanıma.
- ❖ Sağlık: Hastalık teşhisi, medikal görüntü analizi.

3.4.1. Tensorflow ve Keras

TensorFlow, Google tarafından geliştirilen açık kaynaklı bir makine öğrenimi ve derin öğrenme kütüphanesidir. TensorFlow, özellikle yapay sinir ağları gibi derin öğrenme modellerinin oluşturulması, eğitilmesi ve dağıtılması için kullanılır. Grafiksel hesaplama yapısı sayesinde, yüksek performanslı hesaplama için CPU ve GPU gibi farklı donanımları etkin bir şekilde kullanabilir. TensorFlow; Python, C++, Java ve diğer dillerle kullanılabilir ve geniş bir topluluk tarafından desteklenmektedir.

Keras ise, özellikle derin öğrenme modellerinin oluşturulması için kullanılan bir yüksek seviye derin öğrenme kütüphanesidir. Keras, basit ve hızlı bir şekilde derin öğrenme modelleri oluşturmak için tasarlanmıştır. TensorFlow, Theano ve Microsoft Cognitive Toolkit gibi farklı arka uçları destekleyerek esnek bir kullanım sunar. Keras, yoğun, erişimli ve tekrarlayan sinir ağları gibi çeşitli derin öğrenme modellerinin oluşturulmasını kolaylaştırır. TensorFlow 2.0'dan itibaren, TensorFlow'un resmi bir yüksek seviye API'si olarak Keras'ı benimsemiş ve TensorFlow Keras API'si haline getirmiştir. Çünkü Tensorflow'un ilk versiyonunun anlaşılması ve kullanılması zor olmuştur. 2019 yılında Keras ile birleşmiş ve birlikte senkronize olarak kullanılması kolaylaşmıştır.



Şekil 3.6.TensorFlow ve Keras [2]

3.5.SPK VE KAP

Sermaye Piyasası Kurulu (SPK), Türkiye'de sermaye piyasalarının düzenlenmesi ve denetlenmesinden sorumlu olan kamu kurumudur. 1981 yılında kurulan SPK, sermaye piyasalarının güvenli, şeffaf ve etkin bir şekilde çalışmasını sağlamak amacıyla çeşitli düzenlemeler yapar.

SPK'nın Başlıca Görevleri:

1.Piyasaların Düzenlenmesi

2.Denetim ve Gözetim

3.Yatırımcı Koruma

4.Eğitim ve Bilgilendirme

Kamuyu Aydınlatma Platformu (KAP), Türkiye'de halka açık şirketler ve sermaye piyasası araçları ihraç eden diğer kuruluşların kamuyu bilgilendirme yükümlülüklerini yerine getirdikleri elektronik bir sistemdir. KAP, yatırımcıların doğru, zamanında ve eşit bilgiye erişimini sağlayarak piyasanın şeffaflığını artırmayı amaçlar. Bu platform üzerinden şirketler, finansal raporlar, faaliyet raporları, özel durum açıklamaları ve diğer önemli bilgileri yatırımcılara duyurur.

KAP sayesinde:

1. Finansal Raporlar: Şirketlerin belirli dönemlerde yayınladıkları mali durum tablosu, gelir tablosu gibi finansal bilgileri içerir.
2. Faaliyet Raporları: Şirketlerin yıllık veya dönemlik faaliyetlerini, performansını ve geleceğe yönelik beklentilerini içeren raporlardır.
3. Özel Durum Açıklamaları: Şirketlerin faaliyetlerinde önemli değişiklikler olduğunda (yeni anlaşmalar, yönetim değişiklikleri, birleşme ve devralmalar vb. yapılan açıklamalardır.
4. Genel Kurul Toplantıları: Şirketlerin genel kurul toplantılarına ilişkin davet, gündem ve toplantı sonuçlarına dair bilgiler.

Sonuç olarak; SPK, sermaye piyasalarının düzenlenmesi ve denetlenmesinden sorumlu olup KAP ise bu piyasalarda faaliyet gösteren şirketlerin kamuyu aydınlatma yükümlülüklerini yerine getirdiği bir platformdur. SPK, KAP üzerinden yapılan bildirimlerin doğruluğunu ve zamanında yapılmasını denetler ve gerekli düzenlemeleri sağlar.Bu iki yapı, Türkiye'de sermaye piyasalarının düzenli, şeffaf ve güvenli bir şekilde işlemlerini sağlayarak yatırımcıların haklarını korur ve piyasalara olan güveni artırır.

3.6. FİNANSAL RAPORLAR

Finansal raporlar, bir şirketin mali durumunu, performansını ve nakit akışlarını gösteren resmi belgelerdir. Yatırımcılar, analistler, kredi verenler ve diğer paydaşlar, şirketin mali durumunu ve gelecekteki potansiyelini değerlendirmek için bu raporları kullanırlar. Finansal raporlar, genellikle yıllık ve üç aylık olarak hazırlanır ve kamuya açıklanır.

3.6.1.Gelir Tablosu

Gelir tablosu, belirli bir dönemde şirketin gelirlerini, giderlerini ve net karını veya zararını gösterir. Gelir tablosunun temel bileşenleri:

- ❖ Gelir: Şirketin mal veya hizmet satışlarından elde ettiği toplam gelir.
- ❖ Satışların Maliyeti: Üretilen ve satılan malların maliyetinden oluşan gider.
- ❖ Brüt Kar: Gelir eksi satışların maliyeti.
- ❖ Faaliyet Giderleri: Şirketin faaliyetlerini sürdürebilmek için yaptığı giderler (satış, genel ve idari giderler, araştırma ve geliştirme giderleri).
- ❖ Faaliyet Karı: Brüt kar eksi faaliyet giderleridir.

- ❖ Faiz ve Vergi Öncesi Kar: Faaliyet karı artı diğer gelirler ve eksi diğer giderler.
- ❖ Net Kar: Vergi ve faiz giderleri çıkarıldıktan sonra kalan kardır.

3.6.2.Bilanço

Bilanço, belirli bir tarihte şirketin varlıklarını, yükümlülüklerini ve özkaynaklarını gösterir. Ayrıca şirketin mali durumunu anlık bir fotoğraf olarak sunar. Bilançoyu oluşturanlar aşağıdaki gibidir:

3.6.2.1.Varlıklar

Şirketin sahip olduğu kaynaklar ve ekonomik değerlerdir. Varlıklar, genellikle dönen varlıklar (nakit, alacaklar, stoklar) ve duran varlıklar (taşınmazlar, makine ve ekipmanlar) olarak ikiye ayrılır.

- ✓ Dönen Varlıklar: Bir yıl veya daha kısa bir süre içinde nakde çevrilebilecek veya tüketilebilecek varlıklardır. Nakit ve nakit benzerleri, ticari alacaklar, stoklar menkul kıymetler, peşin ödenmiş giderlerden oluşur.
- ✓ Duran Varlıklar: Bir yıl veya daha uzun bir süre boyunca işletmenin kullanımında kalacak varlıklardır. Maddi duran varlıklar (arazi, bina, makine vs.) maddi olmayan duran varlıklar (patent, lisans, markalar), finansal duran varlıklardan (hisse senetleri tahvil vs.) oluşur.

3.6.2.2.Yükümlülükler

Şirketin borçlarıdır. Kısa vadeli (bir yıl içinde ödenmesi gereken) ve uzun vadeli (bir yıldan daha uzun sürede ödenmesi gereken) yükümlülükler olarak sınıflandırılır.

- ✓ Kısa Vadeli Yükümlülükler: Bir yıl veya daha kısa bir süre içinde ödenmesi gereken borçlar ve yükümlülüklerdir. Örnek olarak; ticari borçlar (tedarikçilere olan borçlar), kısa vadeli krediler, ödenecek vergiler, cari yükümlülükler (çalışanlara ödenecek ücretler), peşin alınan gelirler verilebilir.
- ✓ Uzun Vadeli Yükümlülükler: Bir yıl veya daha uzun bir süre içinde ödenmesi gereken borçlar ve yükümlülüklerdir. Örnek olarak; uzun vadeli krediler, tahviller (Şirketin çıkardığı ve yatırımcılara sattığı uzun vadeli borç senetleri), kıdem tazminatı karşılığı örnek olarak verilebilir.

3.6.2.3.Özkaynaklar

Varlıkların yükümlülükler çıkarıldıktan sonraki kısmı. Özkaynaklar, hissedarların şirketteki sahiplik payını temsil eder ve genellikle ödenmiş sermaye, kar yedekleri ve dönem karı/zararları içerir.

3.6.3.Nakit Akış Tablosu

Nakit akış tablosu, belirli bir dönemde şirketin nakit girişlerini ve çıkışlarını gösterir. Bu tablo, şirketin nakit akışlarını üç ana faaliyet alanında detaylandırır: işletme faaliyetleri, yatırım faaliyetleri ve finansman faaliyetleridir.

3.6.3.1. İşletme Faaliyetlerinden Nakit Akışları

Şirketin ana faaliyetlerinden kaynaklanan nakit akışları. Net kar, amortisman, işletme sermayesi değişiklikleri gibi kalemleri içerir.

3.6.3.2. Yatırım Faaliyetlerinden Nakit Akışları

Yatırımlar ve varlık alım-satımları ile ilgili nakit akışları. Sabit kıymet alımları ve satımları, uzun vadeli yatırımlar bu kategoride yer alır.

3.6.3.3. Finansman Faaliyetlerinden Nakit Akışları

Borçlanma, sermaye artırım ve temettü ödemeleri gibi finansman ile ilgili nakit akışları. Kredi alımı/geri ödemesi, hisse ihracı ve temettü ödemeleri bu kategoride yer alır.

3.6.4. Özkaynak Değişim Tablosu

Özkaynak değişim tablosu, belirli bir dönemde şirketin özkaynaklarında meydana gelen değişiklikleri gösterir. Bu tablo, hissedarlar tarafından yapılan yatırımlar, elde edilen karlar, ödenen temettüler ve diğer özkaynak değişikliklerini detaylandırır. Temel bileşenleri; başlangıç özkaynağı, Net kar/zarar, temettü ödemeleri, bitiş özkaynaklarından oluşur.

Finansal raporlar, yatırımcıların, kredi verenlerin, analistlerin ve yöneticilerin şirketin mali sağlığını değerlendirmesine yardımcı olur. Bu raporlar, şirketin karlılığını, likiditesini, borçluluğunu ve genel finansal performansını analiz etmek için kullanılır. Ayrıca, finansal raporlar, şirketin gelecekteki performansı hakkında tahminler yapmaya yardımcı olur ve stratejik kararların alınmasında önemli bir rol oynar.

3.7.KORELASYON ANALİZİ

Korelasyon analizi, iki veya daha fazla değişken arasındaki doğrusal ilişkiyi belirlemeye yönelik bir istatistiksel tekniktir. Korelasyon, değişkenlerin birbirleriyle ne kadar ve hangi yönde ilişkili olduğunu gösterir. Korelasyon katsayısı, bu ilişkinin gücünü ve yönünü sayısal olarak ifade eder.

3.7.1.Korealasyon Katsayısı

Korelasyon katsayısı, genellikle Pearson korelasyon katsayısı olarak bilinir ve -1 ile +1 arasında bir değer alır:

- +1: İki değişken arasında pozitif bir ilişki vardır. Bir değişken arttıkça diğer değişken de artar.
- 0: İki değişken arasında doğrusal bir ilişki saptanamamıştır.
- -1: İki değişken arasında mükemmel negatif doğrusal ilişki vardır. Bir değişken arttıkça diğer değişken azalır.

$$r = \frac{N\sum xy - (\sum x)(\sum y)}{\sqrt{[N\sum x^2 - (\sum x)^2][N\sum y^2 - (\sum y)^2]}}$$

Şekil 3.7. Pearson Korelasyon Katsayısı Formülü [1]

r : Pearson Korelasyon Katsayısı

x_i, y_i :Değişkenlerin Gözlem Değerleri

\bar{x}, \bar{y} : Değişken Ortalamaları

3.7.2.Korelasyon Analizinin Adımları

1. Veri Toplama ve Hazırlama: İlgili değişkenler için veri toplanır ve eksik veya hatalı veriler temizlenir.
2. Dağılım Grafiği: Değişkenler arasındaki ilişkiyi görselleştirmek için dağılım grafiği çizilir.
3. Korelasyon Katsayısının Hesabı: Uygun korelasyon katsayısı hesaplanır.
4. Sonuçların Yorumlanması: Korelasyon katsayısı ve grafiğe dayanarak değişkenler arasındaki ilişkinin gücü ve yönü yorumlanır.

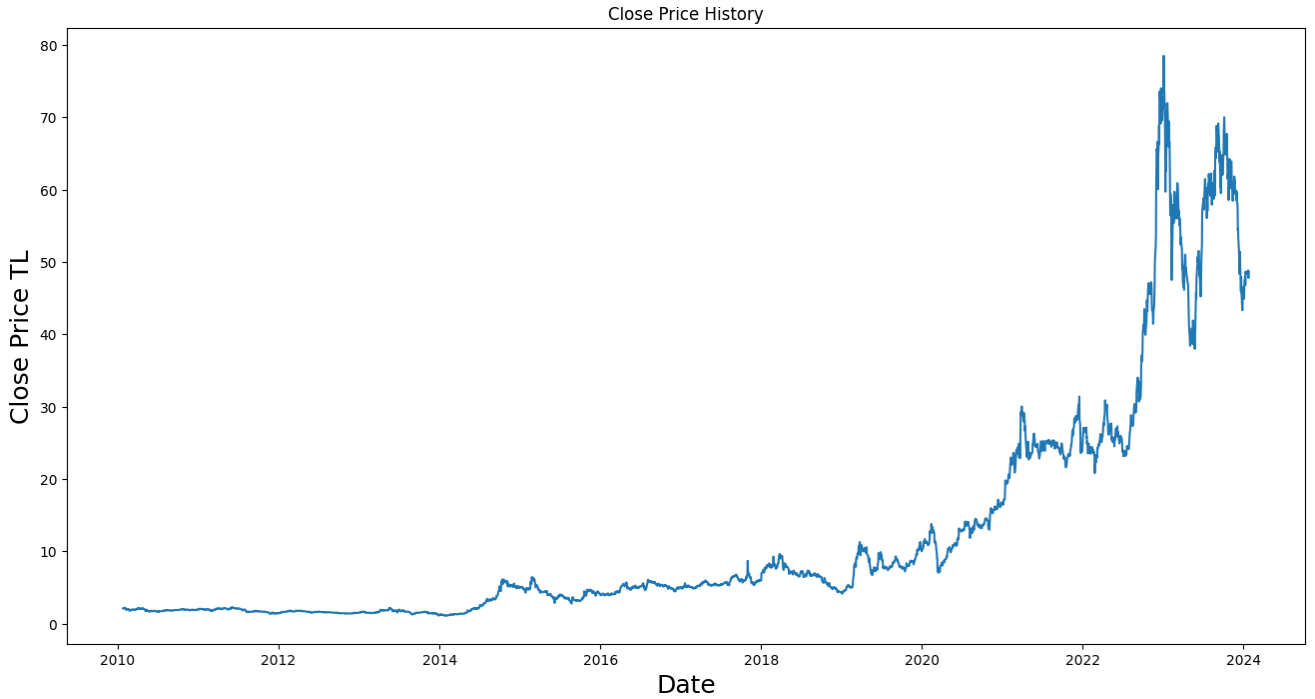
Korelasyon analizi, değişkenler arasındaki ilişkileri anlamak ve tahmin modelleri geliştirmek için önemli bir araçtır. Analiz sonuçları dikkatle yorumlanarak süreç iyileştirilmelidir. Başlıca kullanıldığı sektörler; finans, psikoloji ve sosyoloji, sağlık alanları denilebilir.

4.BULGULAR

Bu çalışmamızda LSTM algoritması kullanılarak VESTEL hissesi için 1 Ocak 2014 yılından başlanarak Haziran 2024 tarihine kadar o günün kapanış verileri ele alınıp model kurmaya ve tahmin yapmaya çalışılmıştır. Bu tahminleme çalışması yapılırken hissenin her üç ayda bir açıklanan faaliyet raporundaki; dönen varlıklar, duran varlıklar, kısa vadeli yükümlülükler, uzun vadeli yükümlülükler, özkaynaklar, hissenin her üç ayda bir hacim değişiklikleri, gelir-gider tablosu kullanılarak korelasyon analizi yapılmıştır. Bu korelasyon analizi sonuçları da çalışmaya eklenip modelde kararlılık ve gerçeklik artırılmaya çalışılmış, RMSE(Root Mean Square Error) hatası düşürülmeye çalışılmıştır.

Normalde kullanılan veri seti 2674 satır ve 7 sütundan oluşmuştur. Sütunlar; o günün tarihi(date), açılış hisse fiyatı(open), o günün en yüksek fiyatı(high), o günün en düşük fiyatı(low), o günün kapanış fiyatı(close), hissenin hacmi(volume), hissenin temettülerinden oluşmaktadır. Hissenin mevcut kapanış verilerinden oluşan grafik aşağıda verilmiştir:

Tablo 4.1.Vestel Hissesi Genel Grafik



4.1.KORELASYON ANALİZİ

Korelasyon analizi, iki veya daha fazla değişken arasındaki doğrusal ilişkiyi belirlemeye yönelik bir istatistiksel tekniktir. Bu kapsamda her üç ayda bir açıklanan finansal raporlardan yola çıkılarak korelasyon analizi 2014 yılından itibaren yapılmıştır.

4.1.1.Toplam Varlıkların Korelasyonu

Toplam varlıklar, dönen varlıklar ve duran varlıkların toplamıdır. Her yılın Mart, Haziran, Eylül ve Aralık aylarında KAP'a açıklanan finansal raporlarda her şirketin toplam varlıkları verisi açıklanır. Bu çalışmada ele alınan VESTEL şirketinin 2014 yılından itibaren her ay için

ortalama hisse fiyatı ve toplam varlıklar değeri hesaplanmıştır. Aralık ayında açıklanan bilançoda toplam varlıklar değeri Aralık, Ocak ve Şubat aylarında; Mart ayında açıklanan bilançoda toplam varlıklar değeri Mart, Nisan ve Mayıs aylarında; Haziran ayında açıklanan bilanço toplam varlıklar değeri Haziran, Temmuz ve Ağustos aylarında; Eylül ayında açıklanan bilançoda toplam varlıklar değeri Eylül, Ekim ve Kasım aylarında kullanılmıştır.

Tablo 4.2.2014-2015-2016 yılları

		2014	Toplam Varlıklar		2015	Toplam Varlıklar		2016	Toplam Varlıklar
Ocak	₺	1,40	₺ 5.636.808,00	₺	6,01	₺ 7.321.345,00	₺	5,16	₺ 9.335.949,00
Şubat	₺	1,56	₺ 5.636.808,00	₺	7,97	₺ 7.321.345,00	₺	5,18	₺ 9.335.949,00
Mart	₺	1,70	₺ 5.913.768,00	₺	5,97	₺ 7.996.300,00	₺	5,87	₺ 9.242.370,00
Nisan	₺	1,89	₺ 5.913.768,00	₺	5,52	₺ 7.996.300,00	₺	7,24	₺ 9.242.370,00
Mayıs	₺	2,57	₺ 5.913.768,00	₺	4,71	₺ 7.996.300,00	₺	6,42	₺ 9.242.370,00
Haziran	₺	2,85	₺ 6.470.063,00	₺	4,90	₺ 8.543.522,00	₺	6,46	₺ 9.314.887,00
Temmuz	₺	3,83	₺ 6.470.063,00	₺	4,58	₺ 8.543.522,00	₺	6,36	₺ 9.314.887,00
Ağustos	₺	4,17	₺ 6.470.063,00	₺	4,54	₺ 8.543.522,00	₺	7,27	₺ 9.314.887,00
Eylül	₺	6,28	₺ 6.736.357,00	₺	3,98	₺ 9.470.295,00	₺	6,63	₺ 9.022.874,00
Ekim	₺	7,36	₺ 6.736.357,00	₺	4,94	₺ 9.470.295,00	₺	6,57	₺ 9.022.874,00
Kasım	₺	6,54	₺ 6.736.357,00	₺	5,57	₺ 9.470.295,00	₺	5,99	₺ 9.022.874,00
Aralık	₺	6,35	₺ 7.321.345,00	₺	5,11	₺ 9.335.949,00	₺	6,35	₺ 9.651.215,00

Tablo 4.3.2017-2018-2019 yılları

	2017	Toplam Varlıklar		2018	Toplam Varlıklar		2019	Toplam Varlıklar
₺	6,50	₺ 9.651.215,00	₺	10,25	₺ 13.845.661,00	₺	6,78	₺ 17.960.822,00
₺	6,12	₺ 9.651.215,00	₺	10,83	₺ 13.845.661,00	₺	10,01	₺ 17.960.822,00
₺	6,95	₺ 10.262.732,00	₺	11,67	₺ 14.734.356,00	₺	12,99	₺ 17.338.267,00
₺	7,29	₺ 10.262.732,00	₺	9,91	₺ 14.734.356,00	₺	12,00	₺ 17.338.267,00
₺	6,88	₺ 10.262.732,00	₺	8,87	₺ 14.734.356,00	₺	9,76	₺ 17.338.267,00
₺	6,87	₺ 11.396.956,00	₺	8,96	₺ 16.098.911,00	₺	12,38	₺ 18.375.892,00
₺	7,20	₺ 11.396.956,00	₺	9,28	₺ 16.098.911,00	₺	9,43	₺ 18.375.892,00
₺	8,36	₺ 11.396.956,00	₺	8,60	₺ 16.098.911,00	₺	10,99	₺ 18.375.892,00
₺	7,51	₺ 12.601.423,00	₺	8,18	₺ 19.376.743,00	₺	10,01	₺ 18.684.678,00
₺	9,88	₺ 12.601.423,00	₺	6,63	₺ 19.376.743,00	₺	10,12	₺ 18.684.678,00
₺	6,87	₺ 12.601.423,00	₺	6,32	₺ 19.376.743,00	₺	11,04	₺ 18.684.678,00
₺	7,57	₺ 13.845.661,00	₺	5,54	₺ 17.960.822,00	₺	12,68	₺ 19.452.405,00

Tablo 4.4.2020-2021-2022 yılları

	2020	Toplam Varlıklar		2021	Toplam Varlıklar		2022	Toplam Varlıklar
₺	13,82	₺19.452.405,00	₺	26,20	₺ 27.078.418,00	₺	24,18	₺ 43.092.689,00
₺	14,20	₺19.452.405,00	₺	26,58	₺ 27.078.418,00	₺	22,52	₺ 43.092.689,00
₺	10,70	₺20.307.361,00	₺	37,50	₺ 29.284.321,00	₺	25,80	₺ 48.800.518,00
₺	13,21	₺20.307.361,00	₺	28,80	₺ 29.284.321,00	₺	26,14	₺ 48.800.518,00
₺	14,10	₺20.307.361,00	₺	31,04	₺ 29.284.321,00	₺	26,96	₺ 48.800.518,00
₺	16,27	₺21.309.475,00	₺	30,30	₺ 31.616.239,00	₺	23,76	₺ 56.777.352,00
₺	17,52	₺21.309.475,00	₺	29,86	₺ 31.616.239,00	₺	24,16	₺ 56.777.352,00
₺	18,39	₺21.309.475,00	₺	28,68	₺ 31.616.239,00	₺	29,68	₺ 56.777.352,00
₺	17,26	₺24.145.527,00	₺	26,30	₺ 31.539.943,00	₺	40,00	₺ 59.659.346,00
₺	16,68	₺24.145.527,00	₺	25,34	₺ 31.539.943,00	₺	46,16	₺ 59.659.346,00
₺	20,04	₺24.145.527,00	₺	28,04	₺ 31.539.943,00	₺	59,65	₺ 59.659.346,00
₺	21,06	₺27.078.418,00	₺	25,04	₺ 43.092.689,00	₺	71,25	₺ 62.872.974,00

Tablo 4.5.2023-2024 yılları

	2023	Toplam Varlıklar		2024	Toplam Varlıklar
₺	63,20	₺ 62.872.974,00	₺	61,45	₺ 125.180.830,00
₺	56,00	₺ 62.872.974,00	₺	83,05	₺ 125.180.830,00
₺	47,32	₺ 65.416.444,00	₺	83,45	
₺	41,30	₺ 65.416.444,00	₺	83,50	
₺	44,92	₺ 65.416.444,00	₺	96,00	
₺	57,00	₺ 81.612.350,00			
₺	61,65	₺ 81.612.350,00			
₺	68,80	₺ 81.612.350,00			
₺	63,40	₺ 88.170.916,00			
₺	60,95	₺ 88.170.916,00			
₺	59,75	₺ 88.170.916,00			
₺	46,24	₺ 125.180.830,00			

12 aylık hisse fiyatları Mart, Haziran, Eylül ve Aralık aylarında açıklanan finansal raporlara göre 3 aylık olarak 3 farklı kritere göre düzenlenmiştir. Örneğin; Aralık, Ocak ve Şubat aylarının toplam varlıkları Aralık ayının raporuna göre alınırken aylık olarak bu üç ayın hisse fiyatı, bu üç aydaki ortalama değer, bu üç aydaki maksimum değer ve bu üç ayda aldığı minimum değere göre matris oluşturulmaya çalışılmıştır.

Tablo 4.6.2014-2015-2016 yılları Hisse Fiyatı ve Toplam Varlıklar

	ORTALAMA		MAKS		MİN		
	Hisse Fiyatı	Toplam Varlıklar	Hisse Fiyatı	Toplam Varlıklar	Hisse Fiyatı	Toplam Varlıklar	
2014	₺ 1,50	₺ 5.636.808,00	₺ 1,56	₺ 5.636.808,00	₺ 1,40	₺ 5.636.808,00	Ara./Ocak/Şub.
	₺ 2,05	₺ 5.913.768,00	₺ 2,57	₺ 5.913.768,00	₺ 1,70	₺ 5.913.768,00	Mart/Nis./May.
	₺ 3,62	₺ 6.470.063,00	₺ 4,17	₺ 6.470.063,00	₺ 2,85	₺ 6.470.063,00	Haz./Tem./Ağ.
	₺ 6,73	₺ 6.736.357,00	₺ 7,36	₺ 6.736.357,00	₺ 6,28	₺ 6.736.357,00	Eyl./Ek./Kas.
2015	₺ 6,78	₺ 7.321.345,00	₺ 7,97	₺ 7.321.345,00	₺ 6,01	₺ 7.321.345,00	Ara./Ocak/Şub.
	₺ 5,40	₺ 7.996.300,00	₺ 5,97	₺ 7.996.300,00	₺ 4,71	₺ 7.996.300,00	Mart/Nis./May.
	₺ 4,67	₺ 8.543.522,00	₺ 4,90	₺ 8.543.522,00	₺ 4,54	₺ 8.543.522,00	Haz./Tem./Ağ.
	₺ 4,83	₺ 9.470.295,00	₺ 5,57	₺ 9.470.295,00	₺ 3,98	₺ 9.470.295,00	Eyl./Ek./Kas.
2016	₺ 5,15	₺ 9.335.949,00	₺ 5,18	₺ 9.335.949,00	₺ 5,11	₺ 9.335.949,00	Ara./Ocak/Şub.
	₺ 6,51	₺ 9.242.370,00	₺ 7,24	₺ 9.242.370,00	₺ 5,87	₺ 9.242.370,00	Mart/Nis./May.
	₺ 6,70	₺ 9.314.887,00	₺ 7,27	₺ 9.314.887,00	₺ 6,36	₺ 9.314.887,00	Haz./Tem./Ağ.
	₺ 6,40	₺ 9.022.874,00	₺ 6,63	₺ 9.022.874,00	₺ 5,99	₺ 9.022.874,00	Eyl./Ek./Kas.

Tablo 4.7.2017-2018-2019 yılları Hisse Fiyatı ve Toplam Varlıklar

2017	₺ 6,32	₺ 9.651.215,00	₺ 6,50	₺ 9.651.215,00	₺ 6,12	₺ 9.651.215,00	Ara./Ocak/Şub.
	₺ 7,04	₺ 10.262.732,00	₺ 7,29	₺ 10.262.732,00	₺ 6,88	₺ 10.262.732,00	Mart/Nis./May.
	₺ 7,48	₺ 11.396.956,00	₺ 8,36	₺ 11.396.956,00	₺ 6,87	₺ 11.396.956,00	Haz./Tem./Ağ.
	₺ 8,09	₺ 12.601.423,00	₺ 9,88	₺ 12.601.423,00	₺ 6,87	₺ 12.601.423,00	Eyl./Ek./Kas.
2018	₺ 9,55	₺ 13.845.661,00	₺ 10,83	₺ 13.845.661,00	₺ 7,57	₺ 13.845.661,00	Ara./Ocak/Şub.
	₺ 10,15	₺ 14.734.356,00	₺ 11,67	₺ 14.734.356,00	₺ 8,87	₺ 14.734.356,00	Mart/Nis./May.
	₺ 8,95	₺ 16.098.911,00	₺ 9,28	₺ 16.098.911,00	₺ 8,60	₺ 16.098.911,00	Haz./Tem./Ağ.
	₺ 7,04	₺ 19.376.743,00	₺ 8,18	₺ 19.376.743,00	₺ 6,32	₺ 19.376.743,00	Eyl./Ek./Kas.
2019	₺ 7,44	₺ 17.960.822,00	₺ 10,01	₺ 17.960.822,00	₺ 5,54	₺ 17.960.822,00	Ara./Ocak/Şub.
	₺ 11,58	₺ 17.338.267,00	₺ 12,99	₺ 17.338.267,00	₺ 9,76	₺ 17.338.267,00	Mart/Nis./May.
	₺ 10,93	₺ 18.375.892,00	₺ 12,38	₺ 18.375.892,00	₺ 9,43	₺ 18.375.892,00	Haz./Tem./Ağ.
	₺ 10,39	₺ 18.684.678,00	₺ 11,04	₺ 18.684.678,00	₺ 10,01	₺ 18.684.678,00	Eyl./Ek./Kas.

Tablo 4.8.2020-2021-2022 yılları Hisse Fiyatı ve Toplam Varlıklar

2020	₺ 13,57	₺ 19.452.405,00	₺ 14,20	₺ 19.452.405,00	₺ 12,68	₺ 19.452.405,00	Ara./Ocak/Şub.
	₺ 12,67	₺ 20.307.361,00	₺ 14,10	₺ 20.307.361,00	₺ 10,70	₺ 20.307.361,00	Mart/Nis./May.
	₺ 17,39	₺ 21.309.475,00	₺ 18,39	₺ 21.309.475,00	₺ 16,27	₺ 21.309.475,00	Haz./Tem./Ağ.
	₺ 17,99	₺ 24.145.527,00	₺ 20,04	₺ 24.145.527,00	₺ 16,68	₺ 24.145.527,00	Eyl./Ek./Kas.
2021	₺ 24,61	₺ 27.078.418,00	₺ 26,58	₺ 27.078.418,00	₺ 21,06	₺ 27.078.418,00	Ara./Ocak/Şub.
	₺ 32,45	₺ 29.284.321,00	₺ 37,50	₺ 29.284.321,00	₺ 28,80	₺ 29.284.321,00	Mart/Nis./May.
	₺ 29,61	₺ 31.616.239,00	₺ 30,30	₺ 31.616.239,00	₺ 28,68	₺ 31.616.239,00	Haz./Tem./Ağ.
	₺ 26,56	₺ 31.539.943,00	₺ 28,04	₺ 31.539.943,00	₺ 25,34	₺ 31.539.943,00	Eyl./Ek./Kas.
2022	₺ 23,91	₺ 43.092.689,00	₺ 25,04	₺ 43.092.689,00	₺ 22,52	₺ 43.092.689,00	Ara./Ocak/Şub.
	₺ 26,30	₺ 48.800.518,00	₺ 26,96	₺ 48.800.518,00	₺ 25,80	₺ 48.800.518,00	Mart/Nis./May.
	₺ 25,87	₺ 56.777.352,00	₺ 29,68	₺ 56.777.352,00	₺ 23,76	₺ 56.777.352,00	Haz./Tem./Ağ.
	₺ 48,60	₺ 59.659.346,00	₺ 59,65	₺ 59.659.346,00	₺ 40,00	₺ 59.659.346,00	Eyl./Ek./Kas.

Tablo 4.9.2023-2024 yılları Hisse Fiyatı ve Toplam Varlıklar

2023	₺	63,48	₺	62.872.974,00	₺	71,25	₺	62.872.974,00	₺	56,00	₺	62.872.974,00	Ara./Ocak/Şub.
	₺	44,51	₺	65.416.444,00	₺	47,32	₺	65.416.444,00	₺	41,30	₺	65.416.444,00	Mart/Nis./May.
	₺	62,48	₺	81.612.350,00	₺	68,80	₺	81.612.350,00	₺	57,00	₺	81.612.350,00	Haz./Tem./Ağ.
	₺	61,37	₺	88.170.916,00	₺	63,40	₺	88.170.916,00	₺	59,75	₺	88.170.916,00	Eyl./Ek./Kas.
2024	₺	63,58	₺	125.180.830,00	₺	83,05	₺	125.180.830,00	₺	46,24	₺	125.180.830,00	Ara./Ocak/Şub.

Tablo 4.10.Korelasyon Analizi Sonuçları

	Sütun 1	Sütun 2		Sütun 1	Sütun 2		Sütun 1	Sütun 2
Sütun 1	1		Sütun 1	1		Sütun 1	1	
Sütun 2	0,938044112	1	Sütun 2	0,94937901	1	Sütun 2	0,912029368	1

Korelasyon analizi sonucunda yukarıda görüldüğü hisse fiyatı 3 ayın ortalama olarak alındığı zaman 0,938044, hisse fiyatı 3 ayın maksimum olanı alındığı zaman 0,949379, hisse fiyatı 3 ayın minimum olanı alındığı zaman 0,912093 olarak hesaplanmıştır. Bu bulunan üç değişken modele eklenecektir.

4.1.2.Hacim Değerlerinin Korelasyonu

Bir hissenin hacim değeri, belirli bir zaman diliminde (genellikle bir gün) o hisse senedinin alınıp satıldığı toplam birim sayısını ifade eder. Hacim değeri, yatırımcıların bir hisse senedine olan ilgisini ve o hissede ne kadar işlem yapıldığını gösteren önemli bir piyasa metriğidir. Hacim, borsa verilerinde genellikle "volume" olarak belirtilir.

2014 Ocak yılından itibaren aylık olarak VESTEL hissesinin hacim değerleri ile hisse fiyatı Yahoo Finance'den veri olarak çekilmiştir. Toplam Varlıklar korelasyonundaki gibi hacim değerlerini dört kısma bölünüp ortalamaları alınmıştır.(Aralık, Ocak, Şubat hacim değerleri ortalaması alınıp hisse fiyatlarıyla; Mart, Nisan, Mayıs hacim değerleri ortalaması alınıp hisse fiyatlarıyla; Haziran, Temmuz, Ağustos hacim değerleri ortalaması alınıp hisse fiyatlarıyla; Eylül, Ekim, Kasım hacim değerleri ortalaması alınıp hisse fiyatlarıyla karşılaştırılmıştır.) Hisse fiyatları üç ayın ortalama, en yüksek ve en düşük verisine göre alınıp üç ayrı korelasyon olarak hesaplamak amaçlanmıştır.

Tablo 4.11.2014-2015-2016-2017 yılları Hacim Değerleri ve Hisse Fiyatı

		ORTALAMA		MİN.		MAX.	
		Volume	Hisse Fiyatı	Volume	Hisse Fiyatı	Volume	Hisse Fiyatı
Ara./Ocak/Şub.	2014	1179683	₺ 1,503	1179683	₺ 1,40	1179683	₺ 1,56
Mart/Nis./May.		1715311	₺ 2,053	1715311	₺ 1,70	1715311	₺ 2,57
Haz./Tem./Ağ.		4421805	₺ 3,617	4421805	₺ 2,85	4421805	₺ 4,17
Eyl./Ek./Kas.		4961067	₺ 6,727	4961067	₺ 6,28	4961067	₺ 7,36
Ara./Ocak/Şub.	2015	4312359	₺ 6,777	4312359	₺ 6,01	4312359	₺ 7,97
Mart/Nis./May.		3960003	₺ 5,400	3960003	₺ 4,71	3960003	₺ 5,97
Haz./Tem./Ağ.		3751340	₺ 4,673	3751340	₺ 4,54	3751340	₺ 4,90
Eyl./Ek./Kas.		8100179	₺ 4,830	8100179	₺ 3,98	8100179	₺ 5,57
Ara./Ocak/Şub.	2016	9070928	₺ 5,150	9070928	₺ 5,11	9070928	₺ 5,18
Mart/Nis./May.		9344243	₺ 6,510	9344243	₺ 5,87	9344243	₺ 7,24
Haz./Tem./Ağ.		7162415	₺ 6,697	7162415	₺ 6,36	7162415	₺ 7,27
Eyl./Ek./Kas.		5168255	₺ 6,397	5168255	₺ 5,99	5168255	₺ 6,63
Ara./Ocak/Şub.	2017	7465300	₺ 6,323	7465300	₺ 6,12	7465300	₺ 6,50
Mart/Nis./May.		4895148	₺ 7,040	4895148	₺ 6,88	4895148	₺ 7,29
Haz./Tem./Ağ.		7826901	₺ 7,477	7826901	₺ 6,87	7826901	₺ 8,36
Eyl./Ek./Kas.		15868638	₺ 8,087	15868638	₺ 6,87	15868638	₺ 9,88

Tablo 4.12.2018-2019-2021-2022 yılları Hacim Değerleri ve Hisse Fiyatı

		ORTALAMA		MİN.		MAX.	
		Volume	Hisse Fiyatı	Volume	Hisse Fiyatı	Volume	Hisse Fiyatı
Ara./Ocak/Şub.	2018	19053343	₺ 9,550	19053343	₺ 7,57	19053343	₺ 10,83
Mart/Nis./May.		10652619	₺ 10,150	10652619	₺ 8,87	10652619	₺ 11,67
Haz./Tem./Ağ.		5877109	₺ 8,947	5877109	₺ 8,60	5877109	₺ 9,28
Eyl./Ek./Kas.		7417307	₺ 7,043	7417307	₺ 6,32	7417307	₺ 8,18
Ara./Ocak/Şub.	2019	12804545	₺ 7,443	12804545	₺ 5,54	12804545	₺ 10,01
Mart/Nis./May.		10932084	₺ 11,583	10932084	₺ 9,76	10932084	₺ 12,99
Haz./Tem./Ağ.		8101195	₺ 10,933	8101195	₺ 9,43	8101195	₺ 12,38
Eyl./Ek./Kas.		4410849	₺ 10,390	4410849	₺ 10,01	4410849	₺ 11,04
Ara./Ocak/Şub.	2020	8812257	₺ 13,567	8812257	₺ 12,68	8812257	₺ 14,20
Mart/Nis./May.		6587180	₺ 12,670	6587180	₺ 10,70	6587180	₺ 14,10
Haz./Tem./Ağ.		6545737	₺ 17,393	6545737	₺ 16,27	6545737	₺ 18,39
Eyl./Ek./Kas.		4992640	₺ 17,993	4992640	₺ 16,68	4992640	₺ 20,04
Ara./Ocak/Şub.	2021	5853302	₺ 24,613	5853302	₺ 21,06	5853302	₺ 26,58
Mart/Nis./May.		8466975	₺ 32,447	8466975	₺ 28,80	8466975	₺ 37,50
Haz./Tem./Ağ.		3047343	₺ 29,613	3047343	₺ 28,68	3047343	₺ 30,30
Eyl./Ek./Kas.		3353223	₺ 26,560	3353223	₺ 25,34	3353223	₺ 28,04

Tablo 4.13.2022-2023-2024 yılları Hacim Değerleri ve Hisse Fiyatı

		ORTALAMA			MİN.			MAX.		
Ara./Ocak/Şub.	2022	5882211	₺	23,913	5882211	₺	22,52	5882211	₺	25,04
Mart/Nis./May.		9859966	₺	26,300	9859966	₺	25,80	9859966	₺	26,96
Haz./Tem./Ağ.		9890676	₺	25,867	9890676	₺	23,76	9890676	₺	29,68
Eyl./Ek./Kas.		22590826	₺	48,603	22590826	₺	40,00	22590826	₺	59,65
Ara./Ocak/Şub.	2023	14102326	₺	63,483	14102326	₺	56,00	14102326	₺	71,25
Mart/Nis./May.		5360925	₺	44,513	5360925	₺	41,30	5360925	₺	47,32
Haz./Tem./Ağ.		10738216	₺	62,483	10738216	₺	57,00	10738216	₺	68,80
Eyl./Ek./Kas.		7253190	₺	61,367	7253190	₺	59,75	7253190	₺	63,40
Ara./Ocak/Şub.	2024	12512160	₺	63,580	12512160	₺	46,24	12512160	₺	83,05

Tablo 4.14.Hacim Değerleri Korelasyon Analizi

		ORTALAMA		MİN.		MAX.		
	Sütun 1	Sütun 2		Sütun 1	Sütun 2		Sütun 1	Sütun 2
Sütun 1	1		Sütun 1	1		Sütun 1	1	
Sütun 2	0,35879	1	Sütun 2	0,31135	1	Sütun 2	0,3997345	1

Yapılan korelasyon analizi sonucunda hisse fiyatlarının ortalaması alınarak ulaşılan sonuç 0,35879; hisse fiyatlarının minimum olanı alınarak ulaşılan sonuç 0,31135; hisse fiyatlarının maksimum olanı alınarak ulaşılan sonuç 0,39973 olarak hesaplanmıştır.

4.1.3.Gelir Tablosunun Korelasyonu

VESTEL şirketinin 2014 yılından 2024 yılında kadar gelir tablosu kalemleri KAP'tan alınmıştır. Gelir tablosu kalemlerinde sırasıyla; satış gelirleri, satışların maliyeti, brüt kar, esas faaliyet karı, Finansman Geliri (Gideri), Sürdürülen Faaliyetler Vergi Öncesi Kar(Zarar), Dönem Karı(Zararı) verilerinden oluşmaktadır. Açıklanan finansal rapora göre Mart, haziran, Eylül ve Aralık değerleri gösterilmiştir.

Tablo 4.15.2014-2015 yılları

	Mart	Haziran	Eylül	Aralık	Mart	Haziran	Eylül	Aralık	Mart
Satış Gelirleri	₺ 1.697.364,00	₺ 1.924.787,00	₺ 1.868.305,00	₺ 2.276.847,00	₺ 1.807.801,00	₺ 1.930.055,00	₺ 2.508.713,00	₺ 3.003.892,00	₺ 2.248.050,00
Satışların Maliyeti	₺ 1.312.991,00	₺ 1.520.762,00	₺ 1.486.380,00	₺ 1.877.286,00	₺ 1.412.599,00	₺ 1.460.525,00	₺ 1.970.637,00	₺ 2.448.630,00	₺ 1.750.247,00
Brüt Kar(Zarar)	₺ 384.373,00	₺ 404.025,00	₺ 381.925,00	₺ 399.561,00	₺ 395.202,00	₺ 469.530,00	₺ 538.076,00	₺ 555.262,00	₺ 497.803,00
Esas Faaliyet Karı(Zararı)	₺ 119.123,00	₺ 121.084,00	₺ 68.786,00	₺ 62.593,00	₺ 32.923,00	₺ 141.856,00	₺ 29.528,00	₺ 173.811,00	₺ 251.050,00
Finansman Geliri(Gideri)	₺ 119.123,00	₺ 121.084,00	₺ 68.786,00	₺ 62.593,00	₺ 32.923,00	₺ 141.856,00	₺ 29.528,00	₺ 173.811,00	₺ 251.050,00
Sürdürülen Faaliyetler Vergi Öncesi Kar	₺ 66.241,00	₺ 83.461,00	₺ 34.365,00	₺ 11.215,00	₺ 75.773,00	₺ 35.809,00	₺ 63.163,00	₺ 177.305,00	₺ 117.630,00
Dönem Karı(Zararı)	₺ 51.442,00	₺ 78.390,00	₺ 45.511,00	₺ 19.801,00	₺ 74.117,00	₺ 44.774,00	₺ 47.028,00	₺ 144.948,00	₺ 111.155,00
Hisse Fiyatı	₺ 1,70	₺ 2,85	₺ 6,28	₺ 6,35	₺ 5,97	₺ 4,90	₺ 3,98	₺ 5,11	₺ 5,87

Tablo 4.16.2016-2017 yılları

	2016				2017			
	Mart	Haziran	Eylül	Aralık	Mart	Haziran	Eylül	Aralık
Satış Gelirleri	₺ 2.248.050,00	₺ 4.647.720,00	₺ 6.764.675,00	₺ 9.540.994,00	₺ 2.382.874,00	₺ 5.341.299,00	₺ 8.234.481,00	₺ 12.100.938,00
Satışların Maliyeti	₺ 1.750.247,00	₺ 3.614.504,00	₺ 5.307.908,00	₺ 7.426.521,00	₺ 1.904.821,00	₺ 4.241.506,00	₺ 6.573.235,00	₺ 9.673.251,00
Brüt Kar(Zarar)	₺ 497.803,00	₺ 1.033.216,00	₺ 1.456.767,00	₺ 2.114.473,00	₺ 478.053,00	₺ 1.099.793,00	₺ 1.661.246,00	₺ 2.427.687,00
Esas Faaliyet Karı(Zararı)	₺ 251.050,00	₺ 321.852,00	₺ 361.844,00	₺ 363.832,00	₺ 64.613,00	₺ 344.628,00	₺ 399.362,00	₺ 436.488,00
Finansman Geliri(Gideri)	₺ 251.050,00	₺ 321.852,00	₺ 361.844,00	₺ 369.744,00	₺ 64.613,00	₺ 344.628,00	₺ 399.362,00	₺ 436.488,00
Sürdürülen Faaliyetler Vergi Öncesi Kar	₺ 117.630,00	₺ 191.465,00	₺ 295.372,00	₺ 164.148,00	₺ 36.847,00	₺ 120.398,00	₺ 32.654,00	-₺ 15.963,00
Dönem Karı(Zararı)	₺ 111.155,00	₺ 186.999,00	₺ 281.677,00	₺ 184.762,00	₺ 42.365,00	₺ 140.287,00	₺ 86.863,00	₺ 71.341,00
Hisse Fiyatı	₺ 5,87	₺ 6,46	₺ 6,63	₺ 6,35	₺ 6,95	₺ 6,87	₺ 7,51	₺ 7,57

Tablo 4.17.2018-2019 yılları

	2018				2019			
	Mart	Haziran	Eylül	Aralık	Mart	Haziran	Eylül	
Satış Gelirleri	₺ 3.006.142,00	₺ 6.894.222,00	₺ 10.469.145,00	₺ 15.852.300,00	₺ 3.562.533,00	₺ 7.825.967,00	₺ 12.006.532,00	
Satışların Maliyeti	₺ 2.298.865,00	₺ 5.091.891,00	₺ 7.319.605,00	₺ 11.570.079,00	₺ 2.752.890,00	₺ 5.789.879,00	₺ 8.964.779,00	
Brüt Kar(Zarar)	₺ 707.277,00	₺ 1.802.331,00	₺ 3.149.540,00	₺ 4.282.221,00	₺ 809.643,00	₺ 2.036.088,00	₺ 3.041.753,00	
Esas Faaliyet Karı(Zararı)	₺ 79.387,00	₺ 91.587,00	-₺ 300.637,00	₺ 482.128,00	-₺ 42.857,00	₺ 531.856,00	₺ 899.302,00	
Finansman Geliri(Gideri)	₺ 79.387,00	₺ 91.587,00	-₺ 346.637,00	₺ 391.269,00	-₺ 122.865,00	₺ 402.626,00	₺ 744.277,00	
Sürdürülen Faaliyetler Vergi Öncesi Kar	-₺ 60.306,00	₺ 96.597,00	₺ 37.707,00	₺ 443.200,00	-₺ 259.035,00	₺ 24.700,00	₺ 178.883,00	
Dönem Karı(Zararı)	-₺ 25.093,00	₺ 109.819,00	₺ 78.334,00	₺ 400.886,00	-₺ 270.272,00	₺ 50.935,00	₺ 170.617,00	
Hisse Fiyatı	₺ 11,67	₺ 8,96	₺ 8,18	₺ 5,54	₺ 12,99	₺ 12,38	₺ 10,01	

Tablo 4.18.2020-2021 yılları

	2020				2021			
	Mart	Haziran	Eylül	Aralık	Mart	Haziran	Eylül	
Satış Gelirleri	₺ 3.930.802,00	₺ 8.354.599,00	₺ 13.908.029,00	₺ 21.546.180,00	₺ 6.200.674,00	₺ 14.214.582,00	₺ 21.758.573,00	
Satışların Maliyeti	₺ 2.811.591,00	₺ 6.042.107,00	₺ 9.927.167,00	₺ 15.527.830,00	₺ 4.686.895,00	₺ 10.518.214,00	₺ 16.511.433,00	
Brüt Kar(Zarar)	₺ 1.119.211,00	₺ 2.312.492,00	₺ 3.980.862,00	₺ 6.018.350,00	₺ 1.513.779,00	₺ 3.696.368,00	₺ 5.247.140,00	
Esas Faaliyet Karı(Zararı)	₺ 127.715,00	₺ 455.985,00	₺ 734.309,00	₺ 1.946.222,00	₺ 155.056,00	₺ 1.003.686,00	₺ 1.272.987,00	
Finansman Geliri(Gideri)	₺ 56.710,00	₺ 337.691,00	₺ 564.325,00	₺ 1.721.320,00	₺ 129.287,00	₺ 973.779,00	₺ 1.189.192,00	
Sürdürülen Faaliyetler Vergi Öncesi Kar	₺ 271.846,00	₺ 566.104,00	₺ 1.013.579,00	₺ 1.939.281,00	₺ 217.916,00	₺ 981.584,00	₺ 1.255.155,00	
Dönem Karı(Zararı)	₺ 236.474,00	₺ 626.138,00	₺ 1.025.491,00	₺ 1.907.237,00	₺ 259.828,00	₺ 1.036.110,00	₺ 1.253.681,00	
Hisse Fiyatı	₺ 10,70	₺ 16,27	₺ 17,26	₺ 21,06	₺ 37,50	₺ 30,30	₺ 26,30	

Tablo 4.19.2022-2023 yılları

	2022				2023			
	Mart	Haziran	Eylül	Aralık	Mart	Haziran	Eylül	Aralık
Satış Gelirleri	₺ 11.740.874,00	₺ 24.630.676,00	₺ 39.102.347,00	₺ 111.124.940,00	₺ 16.915.099,00	₺ 37.387.287,00	₺ 61.801.919,00	₺ 112.215.734,00
Satışların Maliyeti	₺ 8.952.612,00	₺ 17.715.679,00	₺ 29.067.172,00	₺ 92.235.255,00	₺ 13.316.539,00	₺ 27.527.484,00	₺ 44.297.347,00	₺ 87.243.106,00
Brüt Kar(Zarar)	₺ 2.788.262,00	₺ 6.914.997,00	₺ 10.035.175,00	₺ 18.889.685,00	₺ 3.598.560,00	₺ 9.859.803,00	₺ 17.504.572,00	₺ 24.972.628,00
Esas Faaliyet Karı(Zararı)	-₺ 60.864,00	₺ 571.641,00	₺ 44.267,00	-₺ 7.868.105,00	₺ 266.446,00	-₺ 908.956,00	₺ 1.144.852,00	-₺ 7.695.288,00
Finansman Geliri(Gideri)	-₺ 76.272,00	₺ 576.641,00	₺ 134.274,00	-₺ 6.236.686,00	₺ 194.513,00	-₺ 1.275.832,00	₺ 452.678,00	-₺ 6.814.705,00
Sürdürülen Faaliyetler Vergi Öncesi Kar	₺ 473.125,00	₺ 1.289.971,00	₺ 930.143,00	₺ 340.121,00	-₺ 168.004,00	₺ 993.547,00	₺ 315.219,00	₺ 3.015.028,00
Dönem Karı(Zararı)	₺ 592.604,00	₺ 1.496.321,00	₺ 1.214.605,00	₺ 191.486,00	₺ 33.172,00	-₺ 470.912,00	₺ 1.272.886,00	₺ 2.331.159,00
Hisse Fiyatı	₺ 25,80	₺ 23,76	₺ 40,00	₺ 71,25	₺ 47,32	₺ 57,00	₺ 63,40	₺ 46,24

Korelasyon Analizi Toplam Varlıklar ve Hacim Değerlerinde olduğu gibi yapılmıştır. Aralık, Ocak, Şubat dönem karı(zararı) değerleri ortalaması alınıp hisse fiyatlarıyla; Mart, Nisan, Mayıs dönem karı(zararı) değerleri ortalaması alınıp hisse fiyatlarıyla; Haziran, Temmuz, Ağustos dönem karı(zararı) değerleri ortalaması alınıp hisse fiyatlarıyla; Eylül, Ekim, Kasım dönem karı(zararı) ortalaması alınıp hisse fiyatlarıyla karşılaştırılmıştır. Burada hisse fiyatlarının sadece ortalaması ile matris oluşturulmuştur.

Tablo 4.20.2014-2018 yılları

	Hisse Fiyatı	Dönem Karı(Zararı)	
2014	₺ 1,50	-₺ 99.271,00	Ara./Ocak/Şub.
	₺ 2,05	₺ 51.442,00	Mart/Nis./May.
	₺ 3,62	₺ 78.390,00	Haz./Tem./Ağ.
	₺ 6,73	-₺ 45.511,00	Eyl./Ek./Kas.
2015	₺ 6,78	₺ 19.801,00	Ara./Ocak/Şub.
	₺ 5,40	-₺ 74.117,00	Mart/Nis./May.
	₺ 4,67	₺ 44.774,00	Haz./Tem./Ağ.
	₺ 4,83	-₺ 47.028,00	Eyl./Ek./Kas.
2016	₺ 5,15	₺ 144.948,00	Ara./Ocak/Şub.
	₺ 6,51	₺ 111.155,00	Mart/Nis./May.
	₺ 6,70	₺ 186.999,00	Haz./Tem./Ağ.
	₺ 6,40	₺ 281.677,00	Eyl./Ek./Kas.
2017	₺ 6,32	₺ 184.762,00	Ara./Ocak/Şub.
	₺ 7,04	₺ 42.365,00	Mart/Nis./May.
	₺ 7,48	₺ 140.287,00	Haz./Tem./Ağ.
	₺ 8,09	₺ 86.863,00	Eyl./Ek./Kas.
2018	₺ 9,55	₺ 71.341,00	Ara./Ocak/Şub.
	₺ 10,15	-₺ 25.093,00	Mart/Nis./May.
	₺ 8,95	₺ 109.819,00	Haz./Tem./Ağ.
	₺ 7,04	₺ 78.334,00	Eyl./Ek./Kas.

Tablo 4.21.2019-2023 yılları

2019	₺	11,58	-₺	270.272,00	Mart/Nis./May.
	₺	10,93	₺	50.935,00	Haz./Tem./Ağ.
	₺	10,39	₺	170.617,00	Eyl./Ek./Kas.
2020	₺	13,57	₺	351.850,00	Ara./Ocak/Şub.
	₺	12,67	₺	236.474,00	Mart/Nis./May.
	₺	15,96	₺	626.138,00	Haz./Tem./Ağ.
	₺	17,99	₺	1.025.491,00	Eyl./Ek./Kas.
2021	₺	24,61	₺	1.907.237,00	Ara./Ocak/Şub.
	₺	32,45	₺	259.828,00	Mart/Nis./May.
	₺	29,61	₺	1.036.110,00	Haz./Tem./Ağ.
	₺	26,56	₺	1.253.681,00	Eyl./Ek./Kas.
2022	₺	23,91	₺	2.153.953,00	Ara./Ocak/Şub.
	₺	26,30	₺	592.604,00	Mart/Nis./May.
	₺	25,87	₺	1.496.321,00	Haz./Tem./Ağ.
	₺	48,60	₺	1.214.605,00	Eyl./Ek./Kas.
2023	₺	63,48	₺	191.486,00	Ara./Ocak/Şub.
	₺	44,51	₺	33.172,00	Mart/Nis./May.
	₺	62,48	-₺	470.912,00	Haz./Tem./Ağ.
	₺	61,37	₺	1.272.886,00	Eyl./Ek./Kas.

Tablo 4.22.Korelasyon Analizi Sonuç

	<i>Sütun 1</i>	<i>Sütun 2</i>
Sütun 1	1	
Sütun 2	0,345995275	1

2014 yılından itibaren alınan hisse fiyatları ve dönem karı(zararı) sonuçlarına göre çıkan korelasyon 0,34599 olarak hesaplanmıştır.

Bulunan 3 kategoride toplam yedi korelasyon değeri modele eklenecektir. Bu modele eklemeye tekrarlama yapılarak tüm sütunlara aktive edilecektir. (Örneğin dönem karı(zararı) korelasyon değeri tüm satırlarda 0,34559 olarak tekrarlanacaktır.)


4.2.LSTM MODELİ

LSTM yapısında 10 veri input 11. Veri output olarak alınarak fonksiyon kurulmuştur. Burada 10 alınmasını sebebi yapılan tekrarlar sonucunda 10 günde bir hafızaya atılması istenmektedir.Verit seti train ve test olarak train test split fonksiyonu bölünmüştür. Ardından scale işlemi ile normalizasyon yapılmıştır. LSTM modeli kurulmadan önce reshape fonksiyonu ile yeniden boyutlandırma yapılarak formata uygun hale getirilmiştir.

Ardından model oluşturulmuş ve uygunluk işlemi (model.fit) beş kere tekrarlanır. Burada doğruya yaklaşmak için fit işleminin üç kere tekrarlanması denenerek kararlaştırılmıştır. Modeldeki fit işlemi sonuçları 0.0070, 4.0757e-04, 3.5272e-04 olarak hesaplanmıştır.

Train ve test verileri göz önüne alınarak tahminleme prediction işlemi yapılmıştır. Oluşan plot grafiği ile tahminleme işlemi:

Tablo 4.23. Model Plot Grafiği



Modelin hata oranı 0.041275048374413446 olarak hesaplanmıştır. Bu da modeldeki doğruluk oranının yaklaşık olarak %97 olduğunu göstermiştir. Hesaplanan RMSE (Root Mean Squared Error) değeri 0.0018988568301194432 olarak hesaplanmıştır.

4.3.EXTRATREES (EXTREMELY RANDOMIZED TREES)

ExtraTrees (Extremely Randomized Trees) olarak bilinen, bir topluluk (topluluk) öğrenme yöntemidir. Bu yöntem, karar ağaçlarının bir araya getirilmesini sağlar ve bu ağaçların varlığını birleştirerek daha güçlü ve genel yapılabilir modeller üretir. ExtraTrees, özellikle rastgelelik faktörünü artırarak modelin çeşitliliğini ve dolayısıyla performansını artırır.

4.3.1.ExtraTrees Özellikleri

1. Rastgele Ayırık Noktalar: Ayırık noktalar (bölünmüş noktalar) rastgele seçilir, bu da modeli daha çeşitlendirilmiş ve daha az bilinen hale getirilir.
2. Bootstrap Kullanımı: Her ağaç, tüm veri ayarları üzerinde eğitim alır, bu da hata varyansını azaltabilir
3. Topluluk Yapısı: Birçok karar ağacı oluşturur ve her bir ağaç bağımsız olarak toplanır. Nihai tahmin regresyon veya sınıflandırma için yapılır.

4. Hız ve Performans: Rastgele ayrı noktaların kullanılması, her bir ağacın oluşturulma sürecinin hızlandırılması sağlanır.

VESTEL hisse senedi fiyatı modeli için kullanılan bir diğer çalışma ExtraTrees algoritmasıdır. Bu algoritmaya göre, LSTM algoritmasındaki gibi 10 günlük veriler alınıp inputs diye isimlendirilip 11.gün outputs diye isimlendirilir. Yapılan analizin sonucunda modelin hata oranı 0,02387 olarak hesaplanmıştır.

LSTM ve ExtraTrees algoritmalarının her ikisi için de model oluşturulmuş ve modelin tahmin değeri ile hata oranları hesaplanmıştır. LSTM modelinin hata oranı 0,0412754 olurken ExtraTrees modelinin hata oranı 0,02387 olarak hesaplanmıştır. Bu sonuçla ExtraTrees algoritmasının modeli daha iyi tahmin ettiği sonucuna ulaşılır.

5.TARTIŞMA VE SONUÇ

Çağımızda veriler önemli bir yere sahiptir. Verilerin davranışının tespiti ve analizi ile trend noktalarının belirlenmesine yönelik çalışmalarla belirlenen ilkelere ulaşılabilir. Çünkü artık dünyada herhangi bir fazlalık yerine ihtiyaç kadar üretim yapmak her yerde kıstas olarak kullanılmaktadır.

Finans alanında yapılan yatırımlar için de analizler ve hisse davranışı önemli bir yere sahiptir. Çünkü hisse fiyatlarının tarihlere göre değişimi altında oluşan grafik ile yapılan analizler insanlara yatırım konusunda yön gösterecektir. Aynı şekilde şirketin kendi disiplininin de para akışı olarak kamuoyuna bilgilendirildiği asıl platformun hisse olduğunu sayarsak davranış analizi herhangi bir şirketin yatırım almasının da önünü açacaktır.

Bu çalışmada, VESTEL şirketinin hisse senedi fiyatının tahmin edilmesi için bir RNN yapısı olan LSTM modelleme yaklaşımı ve Random Forest yapısı olan ExtraTrees modeli kullanılarak analizler yapılmıştır. LSTM modeli yapılırken şirketin KAP'a bildirdiği finansal tablolardan yola çıkılarak toplam varlıklar, hacim değişimi, dönem karı verileri alınmıştır. Bu veriler ile korelasyon analizi yapılarak artış azalış incelenmiş ve modele uyarlanmak amaçlanmıştır. Çünkü bu veriler bir şirketin hisse fiyatına doğrudan etki edecek veriler olmakla beraber modelin tahmin doğruluğunu artırmada önemli parametrelerdir.

Yapılan analizler sonucunda, geçmiş verilere dayalı olarak VESTEL şirketinin hisse senedi doğruluk (accuracy) oranı LSTM için 0,958725 olurken ExtraTrees algoritması için doğruluk (accuracy) değeri 0,976123 olarak bulunmuştur. Bu sonuçlarla ExtraTrees algoritması VESTEL hisse senedi fiyat modeli oluşturmada daha başarılı çıkmıştır. Modellerin doğruluk oranları güvenilirliğini göstermektedir. Çeşitli senaryolar altında yapılan simülasyonlarla, modellerin gelecekteki fiyat hareketlerini tahmin etme yeteneğinin olduğu da anlaşılmıştır.

Bu çalışma, finansal piyasalarda hisse senedi fiyatlarının tahmininde kullanılabilecek etkili bir modelin oluşturulabileceğini göstermiştir. Gelecekteki çalışmalarda, daha geniş veri setleri kullanılarak ve farklı modelleme teknikleri denenerek daha kapsamlı bir analiz yapılması önerilmektedir. Ayrıca, farklı piyasa koşullarında modelin performansının test edilmesi ve gerçek piyasada uygulanabilirliğinin değerlendirilmesi de önemli bir konu olacaktır.

6.KAYNAKÇA

698962. (n.d.).

ALPAY, Ö. (2020). LSTM Mimarisi Kullanarak USD/TRY Fiyat Tahmini. *European Journal of Science and Technology*, 452–456. <https://doi.org/10.31590/ejosat.araconf59>

ARSLANKAYA, S., & TOPRAK, Ş. (2021). Using Machine Learning and Deep Learning Algorithms for Stock Price Prediction. *Uluslararası Muhendislik Arastirma ve Gelistirme Dergisi*, 13(1), 178–192. <https://doi.org/10.29137/umagd.771671>

Bo. (2022). *FOREIGN EXCHANGE RATE FORECASTING BY USING MACHINE LEARNING ALGORITHMS: DEVELOPED VS EMERGING ECONOMIES " OZLEM AKEKMEKÇİ " I.*

ÇETİN, D. T. (2022). Antalya-Isparta-Burdur Bölgesi Konut Fiyat Endeksinin Makroekonomik Göstergeler ve Hisse Senedi Endeksi Kullanılarak Yapay Zekâ İle Tahmini. *Abant Sosyal Bilimler Dergisi*, 22(3), 1363–1380. <https://doi.org/10.11616/asbi.1161592>

ÇINAROĞLU, E., & AVCI, T. (2020). THY Hisse Senedi Değerinin Yapay Sinir Ağları İle Tahmini. *Atatürk Üniversitesi İktisadi ve İdari Bilimler Dergisi*. <https://doi.org/10.16951/atauniiibd.530322>

[1] ÇOBANOV, M., 2017, Python ile zaman serisi, <https://mertcobanov.medium.com>, [Ziyaret Tarihi : 23 Ocak 2024]

CREDIT RISK ANALYSIS USING MACHINE-LEARNING ALGORITHMS. (n.d.).

ĞSTANBUL TEKNİK ÜNİVERSİTESİ ↔ FEN BİLGİLERİ ENSTİTÜSÜ YÜKSEK LİSANS TEZİ OCAK 2013 KAR YAĞIĞLI GÜN SAYILARININ TOPLAM YAĞIĞLI GÜN SAYILARINA ORANININ YILLIK VE BÖLGESEL TREND ANALİZİ. (n.d.).

KOÇ USTALI, N., TOSUN, N., & TOSUN, Ö. (2021). Makine Öğrenmesi Teknikleri İle Hisse Senedi Fiyat Tahmini. *Eskişehir Osmangazi Üniversitesi İktisadi ve İdari Bilimler Dergisi*, 16(1), 1–16. <https://doi.org/10.17153/oguiibf.636017>

KUZU, H., KARADÖL, H., & AYBEK, A. (2021). Güneydoğu Anadolu Bölgesinde tarımsal mekanizasyon düzeyinin 2010-2019 yıllarındaki değişimi ve gelecek yıllar için trend analizi ile belirlenmesi. *Mustafa Kemal Üniversitesi Tarım Bilimleri Dergisi*, 26(1), 41–62. <https://doi.org/10.37908/mkutbd.767567>


Li, D., Tang, Z., Kang, Q., Zhang, X., & Li, Y. (2023). Machine Learning-Based Method for Predicting Compressive Strength of Concrete. *Processes*, 11(2). <https://doi.org/10.3390/pr11020390>

Mustafa, M., Çalışkan, T., Doç, Y., Onyedi, B., Üniversitesi, E., & Gör, A. (n.d.). *Yapay Sinir Ağlarıyla Hisse Senedi Fiyatları ve Yönlerinin Tahmini Devran DENİZ*.

Orrù, P. F., Zoccheddu, A., Sassu, L., Mattia, C., Cozza, R., & Arena, S. (2020). Machine learning approach using MLP and SVM algorithms for the fault prediction of a centrifugal pump in the oil and gas industry. *Sustainability (Switzerland)*, 12(11). <https://doi.org/10.3390/su12114776>

- Özer, A., Kaya, A., & Özer, N. (n.d.). *Hisse Senedi Fiyatları ile Makroekonomik Değişkenlerin Etkileşimi*.
- Rácz, A., Bajusz, D., Miranda-Quintana, R. A., & Héberger, K. (2021). Machine learning models for classification tasks related to drug safety. *Molecular Diversity*, 25(3), 1409–1424. <https://doi.org/10.1007/s11030-021-10239-x>
- Şener, C., & Şener, U. (2019). MONTE CARLO SİMÜLASYONU İLE HİSSE SENEDİ FİYAT TAHMİNLERİ. *Beykoz Akademi Dergisi*, 7(2), 294–306. <https://doi.org/10.14514/BYK.m.26515393.2019.7/2.294-306>
- Song, Y., Ni, Z., Li, Y., Li, Z., Zhang, J., Guo, D., Yuan, C., Zhang, Z., & Li, Y. (2022). Exploring the landscape, hot topics, and trends of bariatric metabolic surgery with machine learning and bibliometric analysis. *Therapeutic Advances in Gastrointestinal Endoscopy*, 15. <https://doi.org/10.1177/26317745221111944>
- Tamam, İ., & Başer Kolcu, M. İ. (2017). Türkiye’deki Tıp Fakülteleri ile Süleyman Demirel Üniversitesi Tıp Fakültesi Öğrenci Trendinin Değerlendirilmesi. *SDÜ Tıp Fakültesi Dergisi*. <https://doi.org/10.17343/sdutfd.335002>
- [2]Tirendaz Akademi, Makine Öğrenmesi, Keras ve Tensorflow, <https://tirendazakademi.medium.com>, [Ziyaret Tarihi : 23 Ocak 2024]
- Tiwari, D., Bhati, B. S., Al-Turjman, F., & Nagpal, B. (2022). Pandemic coronavirus disease (Covid-19): World effects analysis and prediction using machine-learning techniques. *Expert Systems*, 39(3). <https://doi.org/10.1111/exsy.12714>
- YURTSIZOĞLU, Z. (2021). Salgın Dönemi Kulüp Hisse Değerlerinde Ekonomik Kayıplar (Trend Analizi). *Avrasya Spor Bilimleri ve Eğitim Dergisi*, 3(2), 128–140. <https://doi.org/10.47778/ejsse.993657>

7.EKLER

 `pip install yahoofinancials`

 [Gizli çıkışı göster](#)

```
[ ] # Makine Öğrenmesi Algoritmalarına Dayalı Hisse Senedi Fiyat Tahmini
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import tensorflow as tf
from tensorflow.keras.layers import Dense,LSTM
from tensorflow.keras.models import Sequential
from sklearn.preprocessing import MinMaxScaler
from sklearn.model_selection import train_test_split
import yfinance as yf
from yahoofinancials import YahooFinancials
```

Şekil 7.1.Kodlar-1

```
df = yf.download('VESTL.IS',
                 start = '2014-01-01',
                 progress = False)
```

```
df.index = pd.to_datetime(df.index)
dfClose = df['Close']
```

```
df.head(10)
```

[Gizli çıkışı göster](#)

```
dfClose=dfClose.iloc[:].to_numpy().reshape(-1,1)
```

```
dfClose
```

```
array([[ 1.54999995],
       [ 1.50999999],
       [ 1.52999997],
       ...,
       [82.94999695],
       [82.69999695],
       [81.90000153]])
```

Şekil 7.2.Kodlar-2

```
[ ] type(dfClose)
```

```
⇒ numpy.ndarray
```

```
▶ len(df)
```


```
⇒ 2674
```

```
[ ] len(dfClose)
```

```
⇒ 2674
```

```
[ ] plt.plot(dfClose)  
plt.show()
```

Şekil 7.3.Kodlar-3



Şekil 7.4.Kodlar-4

```

# 10 gün input 11.gün output olarak alındı.
horizon=10
inputs=[]
for i in range(0, len(dfClose)-horizon):
    inputs.append(dfClose[i:(i+horizon)])
inputs=np.array(inputs).reshape(-1,horizon)
outputs=np.array(dfClose[horizon:])
print(inputs.shape, outputs.shape)

(2665, 10) (2665, 1)

[ ] inputs = pd.DataFrame(inputs)

[ ] inputs1 = pd.DataFrame([0.94,0.95,0.912],columns = ['Toplam_Varlıklar'])
inputs2 = pd.DataFrame([0.35,0.31,0.39],columns = ['Volume_Degerler'])
inputs3 = pd.DataFrame([0.34],columns = ['Donem_Kari'])

[ ] repeated_small_df1 = pd.concat([inputs1]*int(np.ceil(len(inputs)/len(inputs1))), ignore_index=True).iloc[:len(inputs)]
repeated_small_df2 = pd.concat([inputs2]*int(np.ceil(len(inputs)/len(inputs2))), ignore_index=True).iloc[:len(inputs)]
repeated_small_df3 = pd.concat([inputs3]*int(np.ceil(len(inputs)/len(inputs3))), ignore_index=True).iloc[:len(inputs)]

[ ] combined_df = pd.concat([inputs, repeated_small_df1, repeated_small_df2, repeated_small_df3], axis=1)
print(combined_df)

```

Şekil 7.5.Kodlar-5

```

[ ] # Standartlaştırma işlemi
scInputs = MinMaxScaler()
scaledInputs = scInputs.fit_transform(inputs)

scOutputs = MinMaxScaler()
scaledOutputs = scOutputs.fit_transform(outputs)

# train_test_split fonksiyonu ile veriyi train ve test olarak ayırma
X_train, X_test, y_train, y_test = train_test_split(scaledInputs, scaledOutputs, test_size=0.2, random_state=42)

print(X_train.shape,y_train.shape,X_test.shape,y_test.shape)

(2127, 10) (2127, 1) (532, 10) (532, 1)

[ ] X_train

```

Şekil 7.6.Kodlar-6


```
array([[0.05343436, 0.0540248 , 0.0556977 , ..., 0.05392639, 0.05412321,
        0.0540248 ],
       [0.17732729, 0.1774257 , 0.18293642, ..., 0.18893918, 0.18362528,
        0.18519977],
       [0.07222988, 0.07449321, 0.07685495, ..., 0.07508365, 0.07577249,
        0.07646132],
       ...,
       [0.08344814, 0.08295612, 0.08187365, ..., 0.07478842, 0.0760677 ,
        0.07449321],
       [0.04270813, 0.04280653, 0.04211769, ..., 0.04074001, 0.0405432 ,
        0.04093682],
       [0.05874828, 0.05924031, 0.05874828, ..., 0.05815784, 0.05815784,
        0.05855147]])
```

```
len(X_train)
```

```
2127
```

```
y_train
```

Şekil 7.7.Kodlar-7

```
array([[0.05313915],
       [0.18500296],
       [0.07646132],
       ...,
       [0.07518206],
       [0.04093682],
       [0.05805944]])
```

```
[ ] len(y_train)
```

```
2127
```

```
[ ] X_test
```

[Gizli çıkışı göster](#)

```
y_test
```

Şekil 7.8.Kodlar-8

```
[ ] # Model
model = Sequential()
model.add(LSTM(128, input_shape=(1,horizon)))
model.add(Dense(63))
model.add(Dense(1))
model.compile(loss = 'mean_squared_error' ,optimizer = 'adam')
```

```
▶ model.summary()
```

```
↗ Model: "sequential_2"
```

Layer (type)	Output Shape	Param #
=====		
lstm_2 (LSTM)	(None, 128)	71168
dense_4 (Dense)	(None, 63)	8127
dense_5 (Dense)	(None, 1)	64
=====		
Total params: 79359 (310.00 KB)		
Trainable params: 79359 (310.00 KB)		
Non-trainable params: 0 (0.00 Byte)		
=====		

Şekil 1.9.Kodlar-9

```
[ ] # fit ve predict işlemi, epochs : Kaç adımda öğrenmeyi yapıcak
model.fit(X_train.reshape(-1,1,horizon),y_train,epochs =3)
```

```
↗ Epoch 1/3
67/67 [=====] - 3s 8ms/step - loss: 0.0070
Epoch 2/3
67/67 [=====] - 0s 7ms/step - loss: 4.0757e-04
Epoch 3/3
67/67 [=====] - 0s 7ms/step - loss: 3.5272e-04
<keras.src.callbacks.History at 0x7d08d6518520>
```

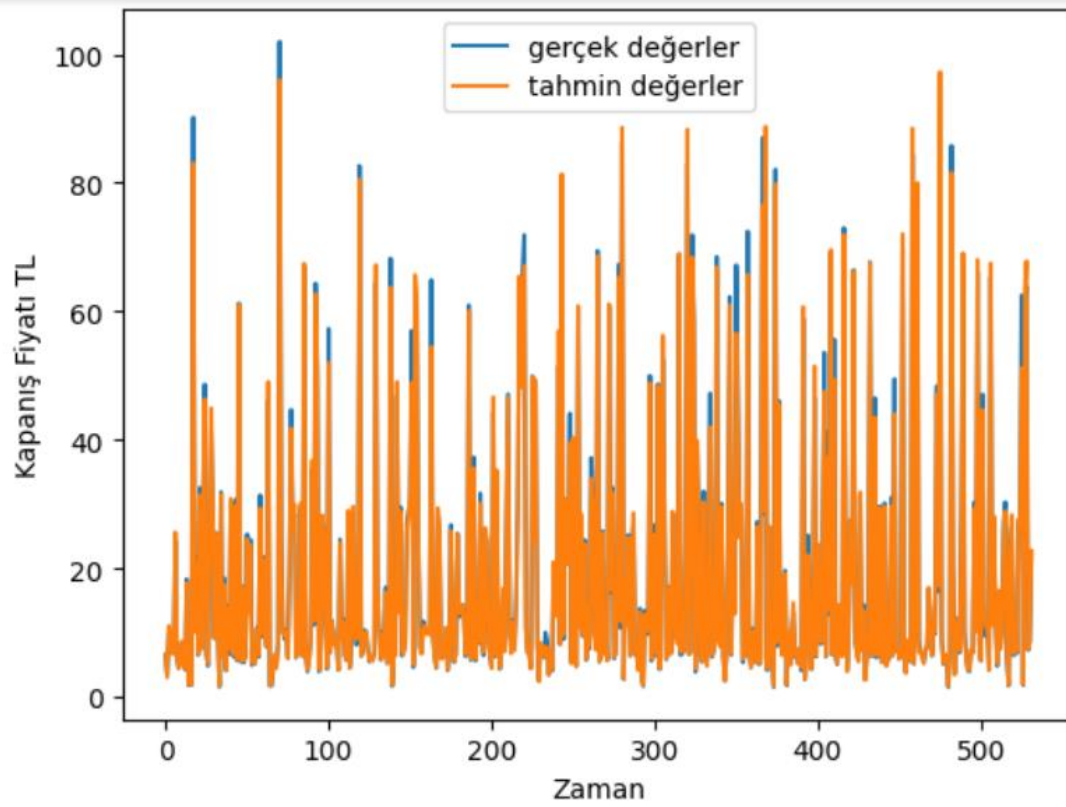
```
▶ y_pred = model.predict(X_test.reshape(-1,1,horizon))
# 0-1 arası tahmin, normalize tersi alma
```

```
↗ 17/17 [=====] - 0s 2ms/step
```

```
[ ] pred=scOutputs.inverse_transform(y_pred)
test=scOutputs.inverse_transform(y_test)
```

```
[ ] plt.plot(test,label = 'gerçek değerler')
plt.plot(pred,label = 'tahmin değerler')
plt.xlabel('Zaman')
plt.ylabel('Kapanış Fiyatı TL')
```

Şekil 7.10.Kodlar-10



Şekil 7.11.Kodlar-11

```
print(np.average(np.abs(pred-test)/test))
```

```
0.041275048374413446
```

```
# Hata  
rmse = np.sqrt(np.mean(y_pred - y_test)**2)
```

```
rmse
```

```
0.0018988568301194432
```

Şekil 7.12.Kodlar-12

```

from sklearn.model_selection import train_test_split
from sklearn.ensemble import ExtraTreesRegressor
from sklearn.metrics import accuracy_score
import numpy as np

X = np.array(inputs)
y = np.array(outputs)

# Veriyi eğitim ve test seti olarak ayıralım
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3, random_state=42)

# ExtraTreesClassifier modelini oluşturalım
model = ExtraTreesRegressor(n_estimators=100, random_state=42)

# Modeli eğitim verisiyle eğitelim
model.fit(X_train, y_train.reshape(-1))

# Test verisiyle tahmin yapalım
y_pred = model.predict(X_test)

# Modelin doğruluğunu hesaplayalım
y_test=y_test.reshape(-1)
accuracy = 1-np.average(np.abs((y_test - y_pred)/y_test))
print(f"Doğruluk Oranı: {accuracy}")

```

Doğruluk Oranı: 0.9761237542588482

Şekil 7.13.Kodlar-13